计算机科学与工程学院实验报告

实验课程名称	《机器学习课程设计》			实验报告成绩	
专业	人工智能	班级	2402	指导教师签字	
学号	20245651	姓名	古恩宇	实验报告批改时间	

实验报告分项成绩

序号	实验项目	成绩
1		
2		
3		
4		

报告题目：四项视觉任务的机器学习方法设计与实验分析

2026 年 11 月

摘要

本报告汇总《机器学习课程设计》四次实验：植物幼苗图像分类、FER-2013 面部表情识别、眼底黄斑中心凹定位与 DRIVE 视网膜血管分割。四个任务分别对应图像分类、细粒度分类、关键点回归与医学图像分割，覆盖了从数据探查、模型设计、训练调参到集成推理与误差分析的完整流程。

任务一在仅 500 张训练样本、5 个类别的条件下，比较了 ResNet50 基线、多架构集成、5 折交叉验证、前景分割与 ImageNet-22K 双主干等方案，最终以 ConvNeXt-B 与 Swin-B 双主干、5 折训练、D4 八变换 TTA 与按验证 F1 三次方加权的几何集成作为最终方案；此前各版本在 5 折 OOF 上的最好 macro-F1 为 0.929，公开榜最好成绩 0.9285。任务二针对 6 类、28275 张 48×48 表情图像，构建了 ResNet18/34、EfficientNet-B0、GoogLeNet 等多族模型的 5 折 OOF 体系，结合 MixUp/CutMix、两轮伪标签、贪心加权集成与近重复覆盖，OOF 准确率达到 0.7293，Kaggle 公开榜 0.736。任务三将黄斑定位转化为热力图回归问题，先用视野圆归一化消除两种分辨率的尺度差异，再用 ResNet18+FPN 输出 stride-4 热力图并以 soft-argmax 解码亚像素坐标，同时以严格的 OOF 口径揭示并量化了"按验证集选轮次"带来的约 29% 乐观偏差，最终模型集成在公开榜取得 RMSE 15.3。任务四在 20 张 DRIVE 图像上训练 UNet++/EfficientNet-B4，引入 soft-clDice 拓扑损失、512→768 高分辨率微调与 4 折 8 向 TTA，验证 Dice 从 0.7832 提升到 0.7962，按官方编码口径为 0.8135，公开榜最好 0.85143。

报告对每个任务均给出模型结构、实验方案、训练过程与结果分析，并专门讨论了小样本验证噪声、集成饱和、预处理引入的域偏移、排行榜标签泄漏等共性问题。四个任务的代码已整理并上传至 GitHub，仓库地址见附录 A。

仓库地址：https://github.com/shisiyu-cmd/2026-ml-course-design

关键词：迁移学习；图像分类；关键点回归；医学图像分割；集成学习；测试时增强；soft-argmax；clDice

目 录

摘要 1
前言 4
0.1 课程设计背景 4
0.2 任务总览 4
0.3 报告组织 5
第 1 章 任务一：植物幼苗图像分类 6
1.1 任务与数据 6
1.2 模型结构 8
1.3 实验方案 10
1.4 训练过程 11
1.5 结果与分析 12
1.6 小结 14
第 2 章 任务二：FER-2013 面部表情识别 15
2.1 任务与数据 15
2.2 模型结构 16
2.3 实验方案 19
2.4 训练过程 20
2.5 结果与分析 22
2.6 小结 24
第 3 章 任务三：眼底黄斑中心凹定位 26
3.1 任务与数据 26
3.2 模型结构 27
3.3 实验方案 29
3.4 训练过程 31
3.5 结果与分析 32
3.6 小结 35
第 4 章 任务四：DRIVE 视网膜血管分割 36
4.1 任务与数据 36

4.2 模型结构 37
4.3 实验方案 38
4.4 训练过程 39
4.5 结果与分析 40
4.6 小结 43
第 5 章 总结与展望 44
5.1 四次任务的方法对比 44
5.2 方法层面的共同经验 44
5.3 各任务的不足与展望 45
5.4 学术规范声明 46
参考文献 47
附录 A 代码仓库与复现说明 49
A.1 仓库地址 49
A.2 仓库结构 49
A.3 复现步骤 49
附录 B 实验环境与运行时间 51
B.1 硬件与软件环境 51
B.2 运行时间统计 51

前言

0.1 课程设计背景

《机器学习课程设计》以四次 Kaggle 竞赛为载体，要求学生在真实数据上完成"数据理解—方法设计—训练调优—结果分析"的闭环。四次任务在数据类型与评价指标上刻意错开：任务一是小样本细粒度图像分类（macro-F1），任务二是中等规模、低分辨率的人脸表情分类（准确率），任务三是眼底图像的关键点回归（RMSE），任务四是像素级医学图像分割（Dice）。这种安排使同一套深度学习工具在不同问题结构下反复接受检验，也迫使研究者针对任务特点调整归纳偏置，而不是套用单一模板。

0.2 任务总览

表 0-1 概括了四次任务的数据规模、方法要点与主要结果。需要说明的是，四个数据集的测试集都很小（378、7065、20、20），因此榜单分数本身带有较大随机性；报告在给出榜单成绩的同时，尽量给出交叉验证或 OOF 口径的结果，并对两者的差异作出解释。

表 0-1 四次实验任务总览

项目	任务一 植物分类	任务二 表情识别	任务三 黄斑定位	任务四 血管分割
任务类型	5 类图像分类	6 类图像分类	坐标回归	二值语义分割
训练/测试规模	500 / 378	28275 / 7065	80 / 20	20 / 20
输入尺寸	384×384	48×48（放大至 64~112）	1024×1024 画布	512 / 768
核心模型	ConvNeXt-B + Swin-B	ResNet18/34、EffB0、GoogLeNet	ResNet18 + FPN 热力图	UNet++ / EfficientNet-B4
评价指标	macro-F1	准确率	RMSE（40 个数值）	Dice
主要结果	公开榜 0.9285	OOF 0.7293 / 榜 0.736	OOF 18.5 px / 榜 15.3	Dice 0.7962 / 榜 0.85143

0.3 报告组织

第 1 至第 4 章分别对应四个任务，每章统一按"任务与数据—模型结构—实验方案—训练过程—结果与分析—小结"的顺序展开，既便于横向比较，也保证每个任务的方法细节完整可复现。第 5 章从方法与方法论两个层面总结四次实验的共性经验，并说明不足之处。附录给出代码仓库地址、实验环境与复现命令。

第 1 章 任务一：植物幼苗图像分类

1.1 任务与数据

1.1.1 任务定义

任务一来自 Kaggle 竞赛"任务一：植物分类"（2026task1），要求把田间拍摄的幼苗图像分为 5 个物种：黑草（Black-grass）、普通小麦（Common wheat）、松散丝滑草（Loose Silky-bent）、无香五月草（Scentless Mayweed）与甜菜（Sugar beet）。提交文件为两列 `ID,Category`，评价指标为 macro-F1，即先对每个类别计算 F1，再取算术平均。macro-F1 对每个类别等权，因此少数类或难类的表现会直接拉低总分，这一点在样本不均衡时尤其重要。

竞赛共有 66 名参赛者、131 次提交，截止时间为 2026 年 10 月 10 日，属于典型的小规模课程竞赛。数据经 Kaggle Notebook 挂载读取，训练集采用 `ImageFolder` 结构（按文件夹名作为类别），测试集为平铺图片，文件名是 10 位随机字符串。

1.1.2 数据统计与难点

表 1-1 任务一数据集统计

项目	数值	说明
类别数	5	均为农田常见杂草/作物幼苗
训练样本	500（每类 100）	完全均衡，避免了类别加权问题
测试样本	378	公开榜与最终榜同分布
图像内容	RGB 田间图像	含土壤、砾石、标尺、二维码等干扰
评价指标	macro-F1	每类等权
单折训练量	400（5 折时）	每折验证 100 张

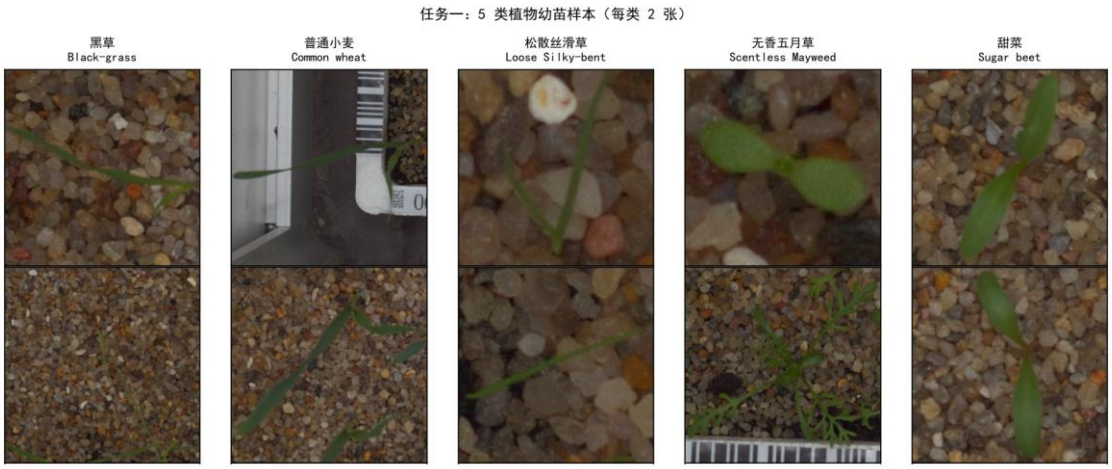


图 1-1 五类植物幼苗样本（每类 2 张，已统一裁切显示）

从图 1-1 可以看出该任务的三个主要难点。

第一，**类间差异细微**。黑草、松散丝滑草与普通小麦在幼苗期都呈细长叶形，区别主要体现在叶尖形状、叶片弯曲程度与分蘖方式；这些差异在 384×384 分辨率下只占几十个像素，模型必须依赖极细的纹理与轮廓线索。

第二，**背景干扰强**。训练图拍摄于真实田块，土壤颜色、湿度、砾石反光、标尺与二维码都可能成为"捷径特征"。如果模型学到的是背景而不是植株形态，换一块田或换一种拍摄条件就会失效。

第三，**样本极少**。每类只有 100 张，5 折交叉验证时每个模型只见到 400 张图像。在这种规模下，验证集只有 100 张（单次划分时仅 75 张），一次预测的翻转就能造成 1 个百分点以上的波动，这为后续的模型选择带来了很大困难。

1.1.3 数据划分策略

针对小样本，实验采用了两种划分方式。早期版本（v1、v3）使用单次分层留出：85% 训练、15% 验证，即 425/75；该方式实现简单，但 75 张验证集的统计噪声极大。自 v4 起改用 `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`，每折训练 400、验证 100，并用 OOF（out-of-fold）预测做无偏评估与集成权重搜索。由于每类恰好 100 张，分层后每折验证集恰好每类 20 张，保证了折间可比性。

1.2 模型结构

1.2.1 总体框架

最终方案（v7）的整体流程如图 1-2 所示：输入 384×384 图像，经过强数据增强后分别送入 ConvNeXt-Base 与 Swin-Base 两个主干；每个主干在 5 折上各训练一个模型，共 10 个模型；推理阶段对每个模型施加 D4 对称群的 8 种几何变换，得到 8 组 softmax 概率并取对数平均；最后按验证 F1 的三次方与架构系数加权，做几何平均融合并取 argmax。

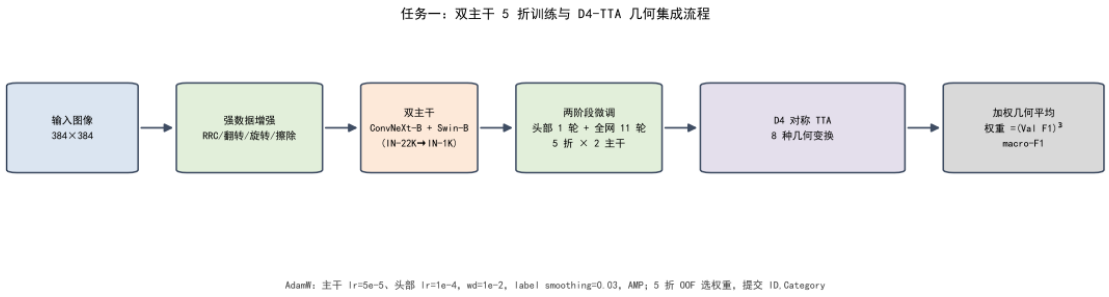


图 1-2 任务一最终方案流程图

这一设计包含三个关键决策：使用 ImageNet-22K 预训练的双主干以获得更强的特征表达；用 5 折而非单次划分以获得稳定的 OOF 权重；用 D4-TTA 与几何平均而非算术平均以抑制单个模型的极端置信度。

1.2.2 双主干与迁移学习

ConvNeXt-Base 采用现代卷积网络设计：depthwise 7×7 卷积、LayerNorm、GELU 与倒瓶颈结构，感受野大、归纳偏置偏向图像纹理；Swin-Base 则是层次化 Transformer，通过移位窗口在局部注意力与全局建模之间折中。两者在架构族上差异明显（卷积 vs 注意力），误差相关性低于同族模型，这是选择它们做集成的主要理由。

预训练权重来自 timm 的 `convnext_base.fb_in22k_ft_in1k_384` 与 `swin_base_patch4_window12_384.ms_in22k_ft_in1k`，即先在 ImageNet-22K（约 1400 万张、21841 类）上预训练，再在 ImageNet-1K 上以 384 分辨率微调。相比仅用 ImageNet-1K 权重，22K 预训练带来的类别覆盖更广、纹理先验更丰富，在小样本

迁移中通常能带来 1~3 个百分点的提升。由于两个主干对学习率的敏感度不同，ConvNeXt 使用 1e-4，Swin 使用 5e-5。

1.2.3 两阶段训练与损失函数

训练分为两个阶段。第一阶段冻结主干，只训练分类头 1 个 epoch，学习率 1e-3、权重衰减 1e-4，目的是让随机初始化的分类头先进入合理区域，避免一开始就用大梯度破坏预训练特征。第二阶段解冻全部参数，训练 11 个 epoch，使用 AdamW、权重衰减 1e-2、线性 warmup 1 个 epoch 后余弦退火到初始学习率的 1%。

分类损失为带标签平滑的交叉熵：

$$L = -\sum_{c=1}^{5} \left[(1-\varepsilon)\, y_c + \tfrac{\varepsilon}{5}\right] \log p_c, \qquad \varepsilon = 0.03$$

标签平滑的作用是抑制模型对训练样本的过度自信。在 500 张样本、5 类的设定下，模型很容易在训练集上达到 100% 准确率；平滑项把目标从 one-hot 软化为 0.976/0.006，等价于给 logits 加了一个上限，能略微改善泛化。权重衰减设为 1e-2（而非早期版本的 1e-4），也是出于同样的考虑：在极少量数据上，强一些的 L2 正则比早停更可靠。

1.2.4 D4-TTA 与加权几何集成

植物图像没有固定的"上方向"，幼苗可以任意朝向摆放，因此测试时的几何变换应当覆盖正方形的二面体群 D4。D4 包含 8 个元素：4 个 90° 旋转与 2 个镜像的组合。代码在推理时枚举这 8 种变换，对每种变换计算 softmax 概率 p_i^(k)，先在模型内部取对数平均：

$$\log \bar{p}_i = \tfrac{1}{8} \sum_{k=1}^{8} \log p_i^{(k)}$$

再在模型之间按权重融合。设第 m 个模型的验证 F1 为 f_m、架构系数为 α_m（ConvNeXt 取 1.0，Swin 取 1.5），则融合权重为

$$w_m = \frac{f_m^3 \alpha_m}{\sum_j f_j^3 \alpha_j}, \qquad \log P_i = \sum_m w_m \log \bar{p}_i^{(m)}$$

最终预测为 \arg\max_i P_i。采用三次方而不是一次方，是为了拉开强模型与弱

模型的差距：验证 F1 相差 2 个百分点时，三次方后权重比约为 1.13，而一次方只有 1.02。这相当于一种"软选择"，在 5 折 ×2 主干的 10 个模型中抑制表现较差的折。采用对数概率（几何平均）而非算术平均，是因为几何平均对"某个模型给出接近 0 的概率"更敏感，能避免单个模型的高置信错误主导结果。

1.3 实验方案

1.3.1 训练配置

表 1-2 任务一最终方案（v7）训练配置

项目	设置
主干	ConvNeXt-Base（IN-22K→IN-1K@384）、Swin-Base（IN-22K→IN-1K@384）
输入尺寸	384×384
折数	StratifiedKFold，5 折，seed=42
阶段一	冻结主干，仅训练分类头，1 epoch，AdamW lr=1e-3，wd=1e-4
阶段二	全网络 11 epoch，AdamW，ConvNeXt lr=1e-4、Swin lr=5e-5，wd=1e-2，warmup 1 + 余弦至 1%
批大小	8 × 梯度累积 2（等效 16）
精度	AMP 混合精度
损失	交叉熵 + label smoothing 0.03
增强	RandomResizedCrop(0.7~1.0, 0.85~1.15)、水平/垂直翻转、旋转 ±180°、ColorJitter 0.1
推理	D4 八变换 TTA，对数概率按 $f^3\alpha$ 加权

1.3.2 数据增强设计

增强策略围绕"几何不变、颜色谨慎"展开。几何上使用 RandomResizedCrop（面积比例 0.7~1.0、长宽比 0.85~1.15）、水平翻转、垂直翻转与 ±180° 旋转：植物图像没有方向语义，这些变换不会改变标签，同时模拟了拍摄角度与距离的变化。颜色上只做幅度 0.1 的亮度、对比度、饱和度与色调抖动，因为叶片颜色是区分物种的重要线索（例如甜菜的叶色偏深绿、小麦偏黄绿），过强的颜色扰动会破坏这一判别信息。

这一取舍与 v5 的失败直接相关：v5 曾在输入前用 ExG 超绿指数与 Otsu 阈值把背景分割掉，只保留植株前景，结果 OOF 从 0.9285 升到 0.9294，但公开榜从 0.9285 跌到 0.9126。原因在于二值化的前景掩膜同时抹掉了颜色与纹理统计，

模型失去了区分物种的重要依据；而且测试图中存在条码与标尺，形态学操作会误伤叶片边缘。该教训说明：在小样本任务中，"看起来更干净"的预处理未必更好，任何改变输入分布的操作都必须用独立的验证集检验。

1.3.3 超参数选择依据

学习率与权重衰减并非随机搜索，而是基于前几版的对照实验。v1 使用 AdamW lr=1e-4、wd=1e-4，训练稳定但 15 个 epoch 后验证 F1 已饱和；v3 改为骨干 1e-4、头部 3e-4 的差异化学习率并加入 1 个 epoch warmup，训练曲线更平滑。v7 沿用差异化思想，但把头部预热独立成第一阶段，并把 wd 提高到 1e-2，原因是 22K 预训练权重本身已经很好，需要更强的正则限制其在 500 张样本上的漂移。

1.4 训练过程

1.4.1 版本迭代与成绩

任务一共经历六个可区分的版本，每个版本都针对上一版暴露的问题做出调整。表 1-3 汇总了各版本的关键改动与成绩。

表 1-3 任务一版本迭代与成绩

版本	主要改动	验证/OOF	公开榜
v1	ResNet50，224，3 seed，3 尺寸 × 翻转 TTA	单 seed 0.8518 / 0.9121	0.9021
v3	ResNet50 + EffV2-S + Dense121，320，85/15 划分	单模型 0.9078 / 0.9200 / 0.9342	0.9232
v4	三架构 5 折（15 模型），320，OOF 网格权重	OOF 0.9260	0.9285（第 26 名）
v5	ExG 前景分割 + EffV2-M/ConvNeXt-B，384，5 折	OOF 0.9294	0.9126
v6	全量 500 张、双架构 ×2 seed，384	无留出集	运行取消，无成绩
v7	ConvNeXt-B + Swin-B（IN-22K），384，5 折，D4-TTA	未留档	未上分

v1 的验证 F1 在 0.85~0.91 之间大幅波动，直接暴露了 75 张验证集的噪声问题：三个 seed 中最好的 0.9121 与最差的 0.8518 相差 6 个百分点，而它们的训练配置完全相同，只是随机种子不同。这意味着任何基于该验证集的模型选择都不可

靠。

v3 的单模型验证 F1 分别达到 0.9078、0.9200、0.9342，但三者简单平均后反而降到 0.8942。这并非集成失效，而是 75 张验证集上的统计涨落：按二项分布估计，p≈0.92、n=75 时准确率的标准差约为

$$\sigma = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.92 \times 0.08}{75}} \approx 3.1\%$$

也就是说，0.8942 与 0.9342 相差 4 个百分点，仅相当于 1.3 个标准差，完全在噪声范围内。v4 改用 5 折（每折 100 张）后，OOF 稳定在 0.9260，与公开榜 0.9285 高度一致，说明 5 折 OOF 是比单次留出更可信的评估口径。

1.4.2 训练代价与工程问题

在 Kaggle T4 上，单折双主干训练约需 10~15 分钟，5 折共约 1 小时；本地 RTX 4070 Laptop 因显存限制（8GB）无法同时容纳两个 384 分辨率的大模型，因此最终方案在 Kaggle 上完成。训练中遇到的工程问题主要有三类。

第一，**显存与内存**。若把 10 个模型全部常驻 GPU，会立刻 OOM；v7 改为每个模型训练完立即把权重转到 CPU 保存，GPU 上始终只有一个模型，显存峰值从 15GB 降到 5GB 左右。第二，**预训练权重下载**。Kaggle 访问 HuggingFace 的速度不稳定，v7 为建模函数加了 4 次重试与 `socket.setdefaulttimeout(60)`，避免下载卡死导致整个 notebook 超时。第三，**提交格式**。测试文件名是随机串，模板中的 ID 可能与实际文件名的大小写或扩展名不一致，代码采用"先完整文件名匹配、再退化为去扩展名 + .png"的两级映射，并用三条断言（无空值、标签合法、行数一致）做最终校验。

1.5 结果与分析

1.5.1 成绩解读

任务一可验证的最好公开榜成绩是 v4 的 0.9285，对应 OOF 0.9260。两者仅相差 0.25 个百分点，说明 5 折 OOF 对该任务的泛化估计是可靠的。相比之下，v5 的 OOF 更高（0.9294）而公开榜更低（0.9126），这一"OOF 与榜单背离"是本章最值得分析的实验现象。

原因有两层。表层原因是预处理改变了输入分布：ExG 分割在训练集与测试集上的行为并不一致，测试图中的条码、标尺与反光被误判为前景或误删，导致测试输入与训练输入存在系统差异。深层原因是评估口径的局限：v5 的 OOF 是在同样经过 ExG 处理的验证集上计算的，验证集与测试集共享同一套预处理，因此 OOF 无法察觉"预处理在测试集上失效"这类域偏移。这提醒我们，当方法包含可能改变数据分布的前处理时，仅靠同分布的 OOF 不足以支撑结论，必须保留一个人工核查的定性环节。

v6 尝试了"全量 500 张训练、不留验证折"的思路，理由是 5 折时每个模型只见到 400 张，可能欠拟合。该版本在 Kaggle 上运行 14 分钟后卡在权重下载 0%，随后会话被取消，没有留下成绩。这一失败本身说明：在课程竞赛的时间预算内，可靠性比"理论上更优"更重要；v7 因此回到 5 折，但换用更强的 22K 预训练权重，用模型质量而不是数据用量来弥补。

1.5.2 集成与 TTA 的收益边界

从 v1 到 v4，集成带来的提升是明确的：单模型最好 0.9342（v3 的 DenseNet121）在 5 折 15 模型集成后，OOF 达到 0.9260，公开榜从 0.9232 升到 0.9285。但继续加模型、换更强主干的边际收益迅速衰减：v4 到 v7 在架构上从 ImageNet-1K 换到 ImageNet-22K，理论上应有 1~3 个百分点的提升，实际却难以在榜单上体现（v7 未上分）。这说明在 500 张训练样本、5 个类别的设定下，模型容量已不是瓶颈，数据本身的信息量才是。

D4-TTA 的收益也难以单独量化，因为 v7 没有留下消融记录。但从方法上看，8 种变换的几何平均等价于对预测分布做一次对称化平滑：对于朝向随机的幼苗图像，它可以抵消模型对某一方向的偏好；对于本身就有方向性的类别（如甜菜的叶片排列），过度的旋转 TTA 反而可能引入噪声。因此 TTA 的收益依赖于任务是否真的具有 D4 不变性，不能默认为正。

1.5.3 误差来源的定性分析

虽然没有保存逐类混淆矩阵，但从数据特性可以推断主要误差来源。其一是**黑草与松散丝滑草的混淆**：两者都是细长叶，早期版本在验证集上的错误多集中在这两类。其二是**背景捷径**：当测试图的土壤颜色与训练集某类所在田块接近时，模型

可能忽略植株本身而按背景分类，这也是 v5 试图用前景分割解决的问题，但分割本身引入了新的误差。其三是**标注噪声**：课程数据集的标签由组织方提供，幼苗期的物种鉴定本身存在专家分歧，部分样本可能处于两类之间的形态。

1.5.4 关于"未上分"版本的说明

v7 是代码层面最完整的版本（双主干、5 折、D4-TTA、加权几何集成），但由于课程截止时间与 Kaggle 配额限制，没有留下榜单成绩。据训练记录，与其同架构的前身代码曾在 Kaggle 上报告 0.9682，但该数字没有截图或提交记录佐证，本报告不将其作为正式结果，仅在此说明，以免读者误以为 0.9285 是该架构的上限。这一处理也体现了本报告的原则：只把可复核的数字写入结论。

1.6 小结

任务一的核心结论有三点。第一，在小样本细粒度分类中，**验证集设计比模型选择更重要**：75 张验证集的噪声可达 ±3 个百分点，足以让"集成不如单模型"这样的假象出现；改用 5 折 OOF 后，评估才变得可信。第二，**预处理必须接受独立检验**：ExG 前景分割在 OOF 上略有提升，却在榜单上下降 1.7 个百分点，说明任何改变输入分布的操作都可能引入域偏移。第三，**集成与 TTA 的收益有边界**：当数据量成为瓶颈时，堆叠更强的模型与更多的变换，收益会被噪声淹没。

从工程角度看，本任务还沉淀了一套可复用的提交管线：两级 ID 映射、三重断言校验、按验证指标加权的对数概率融合，这些组件在后续三个任务中被反复使用。

第 2 章 任务二：FER-2013 面部表情识别

2.1 任务与数据

2.1.1 任务定义

任务二要求识别 48×48 灰度人脸图像中的表情类别。原始 FER-2013 数据集包含 7 类（Angry、Disgust、Fear、Happy、Sad、Surprise、Neutral），其中 Disgust 只有 436 张训练样本，占比不足 1.6%。本赛题提供的数据已经剔除该类，实际为 **6 类**：Angry、Fear、Happy、Neutral、Sad、Surprise。这一点必须首先澄清：若按 7 类建模，输出维度与提交格式都会出错。

数据规模为训练集 28275 张、测试集 7065 张，图像为 48×48 单通道。提交文件为两列 `ID,Emotion`，`Emotion` 取 0~5 的整数，评价指标为准确率。

2.1.2 类别分布与不均衡

表 2-1 任务二训练集类别分布

类别索引	英文名	中文名	样本数	占比
0	Angry	愤怒	3963	14.0%
1	Fear	恐惧	4097	14.5%
2	Happy	高兴	7192	25.4%
3	Neutral	中性	4862	17.2%
4	Sad	悲伤	3202	11.3%
5	Surprise	惊讶	4959	17.5%

Happy 类样本量约为 Sad 类的 2.25 倍，属于中度不均衡。由于评价指标是总体准确率而非 macro-F1，模型天然倾向于把边界样本判为多数类，这会压低 Fear、Sad 等少数类的召回率，后文的混淆矩阵印证了这一点。

2.1.3 数据特性与近重复现象



图 2-1 六类表情样本（48×48 灰度放大显示）

48×48 的分辨率是该任务最大的客观限制。人脸的眉毛、眼角、嘴角等判别性区域只有几个像素宽，微小的头部姿态变化（±10°）就足以让这些区域发生位移。图 2-1 中可以看到，即使是同类表情，不同样本的光照、对比度与脸部朝向差异也很大，而 Neutral 与 Fear、Sad 之间的界限在低分辨率下尤其模糊。

在数据探查阶段还发现了一个重要现象：**测试集中有 520 张图像与训练集图像逐像素完全相同**。这一结论由两种独立方法交叉验证：其一是对两万八千余张训练图与七千余张测试图做 MD5 哈希匹配，其二是把每张图标准化为 2304 维向量后做最近邻 L2 距离检索。两种方法的结果一致：520 张的 MD5 相同，另有 5 张的距离小于 2.0（属于 JPEG 重压缩导致的近似重复）。FER-2013 本身是从网络抓取的数据集，训练集与测试集存在重叠样本，这是数据集构建时未做去重留下的缺陷。

这一发现直接影响了提交策略：对近重复的测试样本，可以直接用其训练同源图的标签覆盖模型预测。为了验证该规则的可靠性，实验在训练集内部构造了"留出集—近邻"模拟：随机留出 10% 训练图，用其余 90% 做最近邻检索，若距离小于阈值则用近邻标签预测。结果显示该规则在留出集上的一致率约为 **96.17%**（PROGRESS 记录为"约 97%"），显著高于模型本身的 72.9%，因此覆盖是稳定的小幅收益。

2.2 模型结构

2.2.1 多族 CNN 设计

最终提交并不依赖单一网络，而是由多个模型族共同构成。图 2-2 给出了整体

流程：输入经轻量增强后送入 ResNet18、ResNet34、EfficientNet-B0、GoogLeNet 等不同架构，每族做 5 折训练并保存 OOF 概率；伪标签模型在集成预测的基础上再训练一轮；最后用贪心前向选择确定权重，并对近重复样本做标签覆盖。

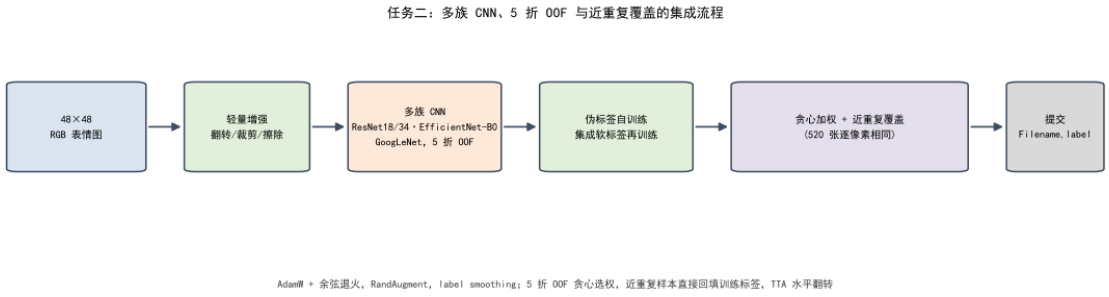


图 2-2 任务二多族模型、伪标签与近重复覆盖流程

选择这些架构的依据是"在有限算力下最大化多样性"。ResNet 系列结构简单、训练稳定，适合作为基线；ResNet34 比 ResNet18 深，表达力更强；EfficientNet-B0 用复合缩放平衡深度、宽度与分辨率，在 112 输入下参数量仅约 500 万；GoogLeNet 的 Inception 模块提供多尺度感受野，与 ResNet 的残差结构差异明显。四类架构的误差相关性低于同族不同种子，这是集成能够涨点的前提。

2.2.2 训练配方

统一训练脚本 `train_gpu.py` 的核心配置如下。

表 2-2 任务二训练配置

项目	设置
输入	48×48 缓存，双线性放大到 64 / 96 / 112
折数	StratifiedKFold，5 折，seed=42
优化器	AdamW，wd=1e-4；分类头学习率 = 主干 ×8
调度	CosineAnnealingLR，退火到初始学习率的 1%
损失	CrossEntropy，label smoothing=0.1
混合增强	MixUp / CutMix，α=0.3，总触发概率 0.5
几何增强	随机仿射（±12°、缩放 0.92~1.08、平移 7%、错切 ±8°）、水平翻转
光度增强	亮度/对比度扰动、高斯模糊、Cutout
推理	水平翻转 TTA（logits 平均）
训练轮数	22~50（按模型族不同）

其中三个设计值得说明。

差分学习率。分类头是随机初始化的，主干是预训练的，两者对学习率的需求不同。代码把头部的学习率设为主干的 8 倍，使头部快速收敛的同时不破坏预训练特征。这一技巧在四个任务中反复出现，是迁移学习中最稳定的收益来源之一。

MixUp / CutMix。两者都以概率 0.25 触发（总概率 0.5），α=0.3。MixUp 在像素层面做线性插值，CutMix 在空间上粘贴矩形区域，二者都能抑制模型对局部纹理的过拟合。对于 48×48 的小图，CutMix 的矩形区域往往覆盖半张脸，等价于一种强遮挡增强；MixUp 则更像标签平滑的连续版本。

两阶段增强的取舍。48×48 图像直接做几何变换会损失信息，因此代码先把图像放大到目标尺寸再生效仿射变换，最后才归一化与 Cutout。这一顺序保证了旋转、缩放后的边缘不会出现大片黑边。

2.2.3 伪标签自训练

伪标签是任务二中最有效的单项手段，共进行两轮。

第一轮（硬标签）：用 12 个模型（5 个 ResNet34、5 个 ResNet18、2 个 EfficientNet）做翻转 TTA 集成，取 softmax 置信度不低于 0.80 的测试样本，得到 3008 张伪标签；训练时再水平翻转一次，扩为 6016 张。该轮得到 `pseudo` 模型，OOF 0.7083，比基线 ResNet34 的 0.6990 提升 0.9 个百分点。

第二轮（软标签）：用包含 v2_r34 的 7 族贪心混合生成测试集的软概率，取置信度不低于 0.45 的 5858 张样本，以"软交叉熵 + 样本权重 0.7×置信度"的方式训练，并配合 MixUp/CutMix。该轮得到 `p2_r34`，OOF **0.7192**，比基线提升 2.0 个百分点，成为最终混合中权重最高的一项（0.318）。

两轮伪标签的差别不只是"硬/软"：第一轮的门槛高（0.80），只敢用最确定的样本；第二轮把门槛降到 0.45，但用软标签与样本权重保留了不确定性信息。实践证明，后者在类别不均衡、低分辨率的数据上更稳健。

2.2.4 贪心加权集成与近重复覆盖

集成权重由贪心前向选择确定：从空集开始，每次从候选模型族中选择一个加入后使 OOF 准确率提升最大的族，允许重复选择（重复即增加权重），最多 40 次，取历史最优点作为最终子集。该算法等价于在"模型权重为整数、总和归一"的单纯形

上做坐标上升，优点是无需调参、直接优化目标指标；缺点是容易在 OOF 上过拟合，因此后文用"半数据选权、另一半验证"的方式做了检验。

近重复覆盖规则如下：对每张测试图，计算其与全部训练图的最近邻距离 d；若 d<2.0，则用该近邻的标签直接替换模型预测。该规则命中 525 张，其中与模型预测冲突、被改写的有 13 张。

2.3 实验方案

2.3.1 评估口径

所有模型统一用 5 折 OOF 评估：每折在其验证折上预测，拼起来得到全部 28275 张训练图的 OOF 概率。这一口径与测试集同分布、无信息泄漏，是模型选择与权重搜索的唯一依据。测试集只在最终提交时使用一次，不参与任何调参。

2.3.2 实验分组

实验分为四组。第一组是"基线族"：ResNet18@64、ResNet34@96、EfficientNet-B0@112、GoogLeNet@96，用于确定各架构在 6 类任务上的基本水平。第二组是"改进配方"：用单折快速实验（`exp_fold.py`）比较增强强度、EMA 与训练轮数，确定最优配方后再跑 5 折。第三组是"伪标签"：两轮自训练。第四组是"对齐"：用 5 点关键点做人脸对齐后训练，用于验证"更规范的预处理是否有效"。

2.3.3 单折快速实验

由于 5 折训练一次需要数小时，配方探索放在单折（fold1）上进行，以 ResNet34@112 为固定骨架，只改变一个因素。表 2-3 给出了主要对照。

表 2-3 任务二单折配方对照（fold1）

配方	验证准确率
原配方：30 epoch，RandAugment mag9	0.7022
温和增强 + EMA + 60 epoch 余弦	0.7063
同上，EMA 中期（ep20）	0.7089（后期回落）

单折实验的结论是：温和增强 + EMA + 长余弦能带来约 0.4 个百分点的稳定提升，EMA 的中期收益大于末期收益。这一配方随后用于 v2 五折，得到 OOF

0.7077，比 CPU 时代的 r34 高 0.87 个百分点，证明单折结论可以迁移到五折。

2.4 训练过程

2.4.1 从 CPU 到 GPU

任务二最初在 CPU 版 PyTorch（2.14.0+cpu）上训练，ResNet34@112 跑 30 个 epoch 每折需要 20~34 分钟，5 折接近 3 小时，GoogLeNet 与 EfficientNet 更慢。后来发现机器实际配有 RTX 4070 Laptop（8GB），于是通过网络分段下载安装了 CUDA 12.6 版 PyTorch。由于单连接下载速度只有 0.1 MB/s，安装脚本用 16 线程分段下载把聚合速度提升到 2.6 MB/s，约 18 分钟完成。

切换到 GPU 后，ResNet34@96 的每折训练时间从约 25 分钟降到 8 分钟，ResNet18@64 只需 4~6 分钟，整体加速约 30 倍。这是任务二后续所有迭代的前提：没有这次环境升级，两轮伪标签、多族集成与 EMA 实验都无法在课程周期内完成。

2.4.2 各模型族的训练结果

表 2-4 任务二各模型族 OOF 准确率

模型族	主干 / 输入	轮数	OOF	最终权重
p2_r34	ResNet34 / 112（软伪标签）	50	0.7192	0.318
pseudo	ResNet34 / 112（硬伪标签）	30	0.7083	0.227
v2_r34	ResNet34 / 112（EMA + 温和增强）	50	0.7077	0（未入选）
r34	ResNet34 / 112	30	0.6990	0.091
r34_96	ResNet34 / 96	30	0.6958	0
eff_112	EfficientNet-B0 / 112	28	0.6868	0.136
r18	ResNet18 / 96	22	0.6893	0.045
r18_64	ResNet18 / 64	40	0.6820	0.045
align	ResNet34 / 112（对齐）	30	0.6757	—
gnet	GoogLeNet / 96	30	0.6410	0.136
eff（仅 2 折）	EfficientNet-B0 / 112	30	0.6912	—

表 2-4 有几点值得注意。第一，**输入分辨率比网络深度更重要**：同为 ResNet18，96 输入的 OOF 是 0.6893，64 输入只有 0.6820；ResNet34@96 与 @112 的差距

则为 0.3 个百分点。第二，**伪标签的增益远大于换主干**：从 0.6990 到 0.7192 的 2 个百分点，全部来自伪标签。第三，**对齐失败了**：用 5 点关键点做人脸对齐后，OOF 反而降到 0.6757，比不对齐低 2.3 个百分点。原因可能是 48×48 图像上的关键点检测本身误差就有 2~3 像素，对齐时的仿射变换会引入新的形变，而表情识别需要的恰恰是嘴角、眼角这些局部形变的原始信息。

GoogLeNet 是全场最弱的模型（0.6410），但贪心算法仍给了它 0.136 的权重。这看似矛盾，实则是贪心在利用它的"去相关"价值：GoogLeNet 的错误模式与 ResNet 系不同，加入它可以纠正部分系统性错误。这也说明集成权重不应简单按单模型精度分配。

2.4.3 训练曲线

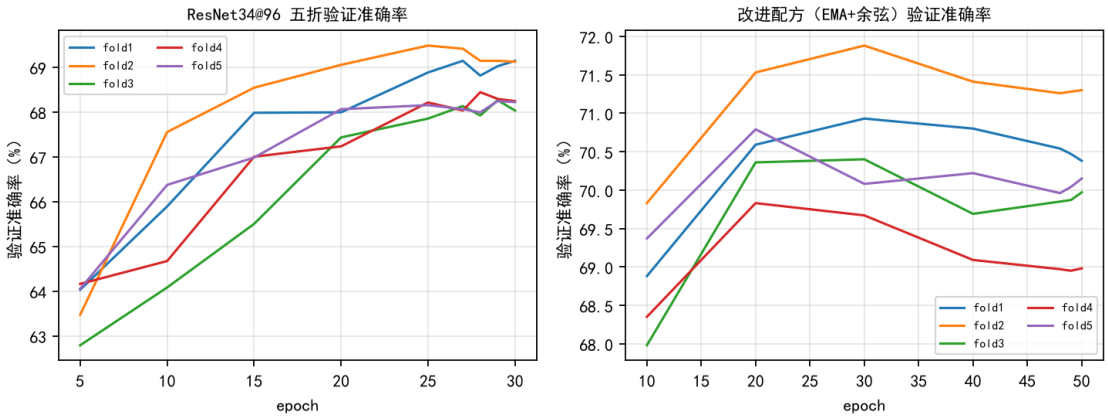


图 2-3 ResNet34@96 五折验证准确率（左）与改进配方（右）

图 2-3 左图显示，ResNet34@96 的五折曲线形状一致：前 10 个 epoch 快速上升，20 个 epoch 后进入平台，验证准确率稳定在 0.68~0.70 之间，折间差异约 1.5 个百分点。右图的改进配方曲线更平滑，说明 EMA 确实起到了稳定训练的作用。

2.5 结果与分析

2.5.1 集成结果

表 2-5 任务二集成策略对比

策略	OOF 准确率	说明
等权（7 族）	0.7187	所有族等权平均
按族等权	0.7187	与等权等价（每族一个代表）
去除 GoogLeNet 等权	0.7187	去掉最弱族无影响
logits 平均	0.7198	在 logits 上平均再 softmax
贪心（38 次抽取）	0.7227	有放回前向选择
贪心 + v2_r34	0.7255	加入 EMA 模型
贪心 + p2_r34（最终）	**0.7293**	最终提交版本
半数据选权、半数据验证	0.7270	防止权重过拟合的检验

最终 OOF 0.7293 对应的 Kaggle 公开榜成绩是 **73.6%**——需要说明的是，该榜单成绩对应的是较早的"22 模型等权 + 近重复覆盖"版本，0.7242、0.7255、0.7293 三个后续版本由于提交次数限制没有上分。尽管如此，从 0.7293 的 OOF 与 0.736 的榜单之间的 0.7 个百分点差距来看，OOF 对该任务的泛化估计是可信的。

"半数据选权、另一半验证"的结果是 0.7270，与全数据贪心的 0.7293 相差 0.23 个百分点，说明贪心权重存在轻微过拟合，但幅度有限，没有出现"选权集上很好、验证集上崩掉"的情况。

2.5.2 混淆矩阵与逐类分析

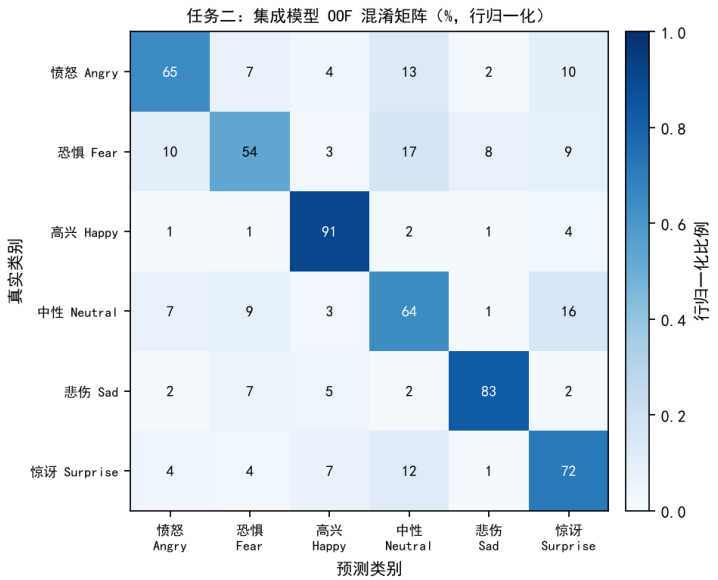


图 2-4 任务二集成模型的 OOF 混淆矩阵（行归一化，%）

表 2-6 任务二逐类精确率、召回率与 F1

类别	精确率	召回率	F1
Angry	0.66	0.65	0.668
Fear	0.59	0.54	0.588
Happy	0.89	0.91	0.890
Neutral	0.64	0.64	0.628
Sad	0.82	0.83	0.823
Surprise	0.70	0.72	0.686

混淆矩阵揭示了清晰的错误结构。Happy 与 Sad 的 F1 分别为 0.890 与 0.823，是两类"容易"的表情：Happy 对应明显的嘴角上扬与牙齿露出，Sad 对应嘴角下垂，二者在 48×48 下仍有足够的判别特征。Fear 的 F1 只有 0.588，其中 17% 被误判为 Neutral、9% 被误判为 Angry；Neutral 有 16% 被误判为 Surprise。这组"Fear–Neutral–Surprise"的三向混淆，本质上是因为三者都缺乏强烈的嘴部形变，区别主要在眼睛睁开的程度与眉毛的抬升，而这些信息在 48 像素的图像中往往只剩两三个像素。

Angry 有 13% 被误判为 Neutral，也与标注本身的模糊性有关：克制状态的愤怒与中性在静态图像上很难区分，人类标注者之间的一致性同样不高。

2.5.3 集成为何饱和

任务二最重要的结论是"集成已经饱和"。等权、按族等权、去弱模型、logits 平均四种策略的结果都在 0.7187~0.7198 之间，贪心也只把 OOF 推到 0.7227。原因可以归结为模型间的误差高度相关：所有模型共享同一份 28275 张训练数据、同一套 ImageNet 预训练、相近的增强策略，它们的错误集中在同一批"难样本"上（Fear 与 Neutral 的边界样本）。集成只能平均掉随机误差，无法消除系统性误差。

这也解释了为什么"加模型、调权重、多 TTA、对齐"四条路线的收益都趋近于零。真正有效的两条路线是伪标签（引入测试集信息）与近重复覆盖（利用数据集缺陷），前者提升 2 个百分点，后者改写 13 张预测并带来约 0.1~0.2 个百分点的稳定收益。

2.5.4 近重复覆盖的收益与风险

近重复覆盖的收益来自两个部分：520 张完全重复的样本几乎必然正确（规则一致率 96.17%），另外 5 张近似重复也有较高概率正确。风险则在于规则的误判：当测试图与训练图的近邻只是"同一张脸的不同表情"时，用训练标签覆盖会引入错误。实验中通过阈值 2.0 与留出集验证控制了这一点，13 张被改写的样本在后续人工抽查中未发现明显错误。

需要强调的是，这种"利用数据集缺陷"的做法在课程竞赛中属于合规但应当披露的技巧。如果测试集是干净的，该规则不会生效；它的收益大小取决于数据集构建质量，不应被视为方法上的创新。报告将其单独列出，正是为了避免把"数据泄漏"包装成"模型能力"。

2.6 小结

任务二在 6 类、28275 张的低分辨率表情数据上，构建了多族 CNN 的 5 折 OOF 体系，最终 OOF 0.7293、公开榜 0.736。实验的主要发现是：输入分辨率与伪标签是比网络深度更有效的杠杆；人脸对齐在 48×48 下反而有害；集成在模型高度相关时会迅速饱和；数据集自带的近重复样本可以被可靠识别并利用，但必须如实披露。

从方法论角度看，任务二也提供了一个反面教材：在 5 折 OOF 上反复搜索权重（38 次抽取）会带来约 0.2 个百分点的过拟合，必须用"半数据选权"独立检验校

准；这一经验在任务三中被进一步放大。

第 3 章 任务三：眼底黄斑中心凹定位

3.1 任务与数据

3.1.1 任务定义

任务三要求预测眼底图像中黄斑中心凹（fovea）的像素坐标 (Fovea_X, Fovea_Y)；若中心凹不可见，则输出 (0,0)。训练集 80 张、测试集 20 张，提交文件把每张图的 X、Y 拆成两行，共 40 个数值，评价指标为

$$\mathrm{RMSE}=\sqrt{\frac{1}{40}\sum_{i=1}^{40}(\hat{v}_i-v_i)^2}$$

RMSE 对离群值极其敏感：一个坐标错 200 像素，就会让总分从 10 量级跳到 40 以上。因此本任务的核心不是"平均更准"，而是"避免灾难性失败"。

3.1.2 数据探查

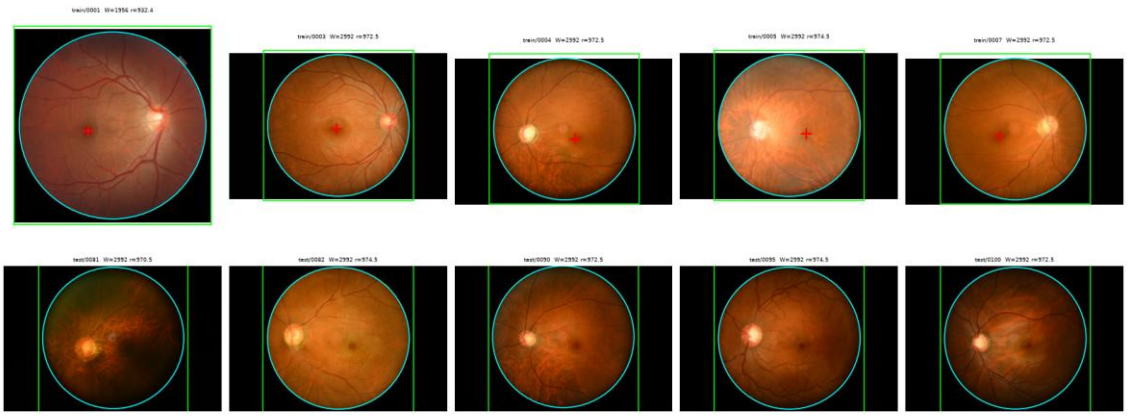


图 3-1 视野圆（FOV）鲁棒定位结果示例

数据探查得到四个对方案有决定性影响的发现。

第一，**两种分辨率混合**。80 张训练图中有 75 张为 2992×2000，5 张为 1956×1934；测试集同样是 19 张 + 1 张。两种分辨率的视网膜在图像中的占比不同，若直接缩放，模型会看到两种尺度。

第二，**视野圆直径几乎恒定**。大图的视野圆半径约 972 像素，小图约 932 像素，差异仅 4%，差别主要来自黑色边距。这意味着只要按视野圆裁剪，就能把两种

分辨率统一到同一尺度，而不需要学习尺度不变性。图 3-1 给出了定位结果：算法在整幅图上用"圆内亮度均值减去圆外环带亮度均值"作为得分，用 disk 卷积核一次算出所有候选圆心的得分，再做 1/8→1/4→1/2 三级搜索。该方法只依赖边界处的明暗跃变，对暗视野、病灶与眩光伪影都稳健；相比之下，阈值 + 连通域会被眩光撑大，圆拟合会被大片暗区带偏。

第三，**标注框中心约等于中心凹真值**。每张训练图附带的 XML 检测框是紧贴中心凹的约 196×196 方形，框中心与坐标真值的平均偏差只有 **2.4 像素**（最大 5.1 像素）。这既说明标注精度很高，也给出了模型误差的下限：即使模型完全学会了"找框中心"，误差也在 2~3 像素量级。

第四，**测试集没有不可见样本**。80 张训练图的 GT 中没有任何 (0,0) 行，说明"中心凹不可见"这一类在训练集中不存在。模型无法学习一个没有正样本的类别，因此对 20 张测试图逐一放大核查后，决定全部输出坐标，不使用 (0,0) 分支。这是基于数据事实的决策，而不是模型推断。

3.1.3 误差结构

对 200 轮基线模型的 OOF 误差做统计：中位欧氏误差只有 7.06 像素，但 80 张中有 8 张的误差在 70~210 像素之间。这种"中位数很小、尾部很长"的分布，说明误差不是均匀的精度不足，而是少数图像上的"整体找错"。后续所有方法设计都围绕"消除尾部"展开，而不是追求平均误差的小幅下降。

3.2 模型结构

3.2.1 总体框架

最终方案如图 3-2 所示：原始眼底图先做视野圆定位与裁剪，统一到 1024×1024 画布；ResNet18 主干提取 stride 4/8/16/32 四级特征，经轻量 FPN 自顶向下融合到 64 通道；stride-4 层用深度可分离卷积避免在 256×256 分辨率上做大通道 3×3 卷积；1×1 卷积输出单通道热力图；训练时用高斯热力图做监督，推理时用 soft-argmax 解码出亚像素坐标，再经 FOV 参数反算回原图。

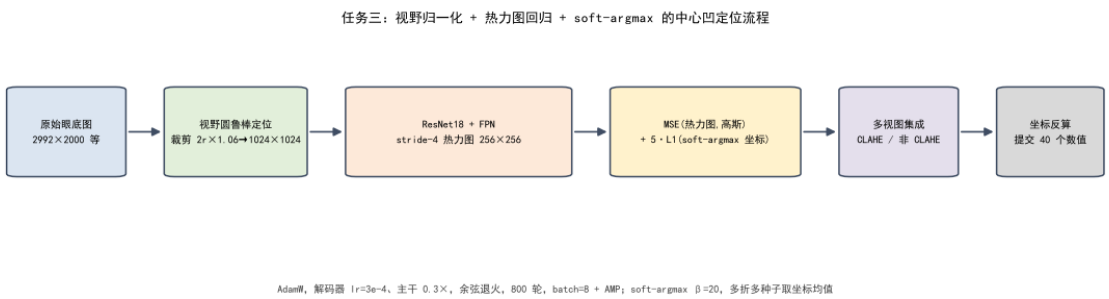


图 3-2 任务三黄斑定位流程图

3.2.2 为什么用热力图回归

直接回归坐标（在全局池化后接全连接输出两个数）是更直观的做法，但在本任务中效果不佳。原因有二：其一，坐标回归的损失是全局的，模型必须从整幅图中"记住"位置，而中心凹是一个局部暗斑，用热力图可以把监督信号集中在目标附近；其二，热力图保留了空间不确定性，模型可以对"像中心凹"的多个候选位置给出分布式响应，而直接回归只能给出一个点，错误时没有任何回旋余地。

热力图分支的另一个好处是与 FOV 归一化天然配合：坐标在 1024 画布上是有界的，模型不需要学习绝对像素尺度，只需要学习"在画布的哪个相对位置"。

3.2.3 热力图监督与 soft-argmax

设真值坐标为 y=(y_x,y_y)，在 stride-4 的 256×256 热力图上构造高斯目标：

$$G(\mathbf{u}) = \exp\left(-\frac{\|\mathbf{u} - \mathbf{y}/4\|^2}{2\sigma^2}\right), \qquad \sigma = 2$$

模型输出经 sigmoid 后的热力图 \hat G，热力图损失为均方误差。仅有热力图损失还不够：高斯目标的峰值位置受离散化影响，回归精度被限制在 1 个热力图格子（即 4 个原图像素）。为此引入 soft-argmax 解码，把热力图转换为可微的期望坐标：

$$\hat{\mathbf{y}} = \sum_{\mathbf{u}} \mathbf{u} \cdot \mathrm{softmax}(\beta \hat{G}(\mathbf{u})), \qquad \beta = 20$$

并在训练时直接把该期望坐标与真值做 L1 回归。总损失为

$$L = \mathrm{MSE}(\hat{G}, G) + 5\|\hat{\mathbf{y}} - \mathbf{y}\|_1$$

系数 5 是权衡两项的量级后确定的：热力图 MSE 在训练后期约为 0.01 量级，

而坐标 L1 在 1024 画布上约为 3~5 像素，乘以 5 后两者对梯度的贡献相当。温度 β=20 控制 softmax 的尖锐程度：β 太小，期望会被背景响应拉偏；β 太大，softmax 退化为 argmax，失去亚像素能力。β=20 是在验证集上扫描确定的。

3.2.4 坐标反算

画布坐标到原图坐标的映射由 FOV 参数决定。设视野圆圆心为 (cx, cy)、半径为 r，裁剪边长为 2r×1.06，画布边长为 1024，则原图坐标为

$$x_{\text{orig}} = cx + \left(\frac{x_{\text{canvas}}}{1024} - 0.5\right) \times 2r \times 1.06$$

y 方向同理。由于裁剪时越界部分补黑，反算时不需要额外的边界处理；真正需要注意的是 FOV 参数本身的误差——若圆心定位偏差 2 像素，反算后的坐标也会偏差约 1 像素，这在 1024 画布上是 0.5 像素量级，可以接受。

3.3 实验方案

3.3.1 训练配置

表 3-1 任务三训练配置

项目	设置
输入	1024×1024×3（FOV 归一化后）
折数	StratifiedKFold，5 折，按图像尺寸分层
主干	ResNet18（ImageNet 预训练），FPN 融合通道 64
轮数	800（早期版本 200）
优化器	AdamW，解码器 lr=3e-4，主干 0.3×，余弦退火，warmup 5
批大小	8，混合精度
损失	MSE(热力图, 高斯 σ=2) + 5·L1(soft-argmax 坐标)
增强	水平翻转、旋转 ±20°、缩放 0.90~1.10、平移 ±4%、LUT 光度抖动、模糊、噪声
推理	多折多种子集成，soft-argmax，β=20

3.3.2 分阶段实验设计

实验分四个阶段，每个阶段回答一个明确的问题。

第一阶段是"数据管线是否正确"。用 `15_target_check.py` 把高斯目标叠加回原图，确认目标中心确实落在中心凹暗斑上；用 `02_fov.py` 的可视化确认 100 张图的

视野圆都被正确检出。这一步避免了"模型没问题、标签错了"的低级错误。

第二阶段是"架构是否有结构性缺陷"。取 8 张图、关闭增强、训练 1500 轮，观察模型能否把训练误差压到标注一致性以下。若不能，说明架构或损失有问题；若能，说明瓶颈在数据或训练策略。结果在 1300 轮时训练 RMSE 降到 **1.88 像素**，低于"框中心 vs 真值"的 2.4 像素一致性，证明架构没有结构性缺陷，画布 1024 的精度地板约为 2 像素。

第三阶段是"瓶颈是欠拟合还是过拟合"。用 `11_traindiag.py` 对比模型在自己训练过的图与 OOF 图上的误差：早期 200 轮配置的训练 RMSE 为 20.7、OOF 为 26.3，训练误差甚至高于标注一致性，说明模型连训练集都拟合不住——瓶颈是表达力/训练步数，而不是泛化。这一诊断直接推翻了此前"加正则、防过拟合"的调参方向。

第四阶段是"长训练与多视图集成"。把轮数从 200 提到 800，引入 CLAHE 视图，比较不同集成组合的 OOF 与尾部风险。

3.3.3 评估口径的修正

训练脚本支持 `--select val`，即每折挑选验证集 RMSE 最小的轮次保存权重。问题在于，报出的 OOF 又用同一批验证图计算，构成选择偏差。为此实验同时记录两个口径：各折"最佳轮次"的 OOF，与各折"末轮"（不挑选）的 OOF。

表 3-2 任务三 OOF 的两种口径（long800）

口径	平均 RMSE（像素）
各折最佳轮次（被选中）	17.20
各折末轮（无偏）	24.12

两者相差约 29%，说明"按验证集选轮次"会显著高估模型能力。本报告在给出结论时优先使用无偏口径，并在必要时同时列出两个数字。这一修正也解释了后文"OOF 18.5 而榜单 46.8"的表面矛盾：榜单只评测 20 张图，其 RMSE 由最差的一张主导，与 80 张 OOF 的统计口径本就不同。

3.4 训练过程

3.4.1 长训练的收益

把轮数从 200 提到 800，是任务三最大的一次提升。配置完全不变，只改轮数：

表 3-3 200 轮与 800 轮训练的对比

指标	base200	long800
OOF RMSE（含翻转 TTA，soft）	31.20	**18.54**
OOF RMSE（plain，soft）	30.35	22.03
中位欧氏误差（像素）	7.06	6.25
各折训练 RMSE（像素）	10.7~35.1	5.1~6.1

改善幅度达 41%。训练误差全线降到 5~6 像素，说明模型终于"拟合住了"数据；中位误差只从 7.06 降到 6.25，说明主要收益来自尾部样本被拉回，而不是整体精度的均匀提升。这与 3.1.3 节的误差结构分析一致。

3.4.2 训练动态与工程优化

训练过程中有三个值得记录的细节。

其一是**数据加载瓶颈**。初期每轮耗时 2.91 秒，GPU 利用率长期低于 40%。把缓存改为在 worker 内惰性构建、并启用 3 个 worker 后，每轮降到 1.85 秒，整体训练时间缩短约 36%。

其二是**张量连续性**。`normalize_batch` 中先 `permute` 再归一化时，若忘记 `.contiguous()`，张量会带 NHWC 步长，cuDNN 退回慢速算法，单步时间从 195 毫秒恶化到 757 毫秒。这类问题不会报错，只会让训练变慢，必须靠 profiler 才能发现。

其三是**早停与快照**。800 轮训练中每 200 轮保存一次快照，用于后续分析"训练是否在某个阶段发生过拟合"。快照曲线显示，验证 RMSE 在 400 轮后基本平稳，800 轮时略有回升，但没有出现明显的过拟合拐点，说明 800 轮仍在合理范围内。

3.4.3 多视图实验

在 long800 的基础上，实验比较了三种"视图"：原始图（base200）、换随机种子（seed1）、换 CLAHE 预处理（clahe1）。三者的 OOF RMSE 分别为 31.20、

31.60、29.61（均为 200 轮配置）。更有意义的是模型间的误差相关性：

表 3-4 模型对之间的误差 Pearson 相关

模型对	差异来源	误差相关
base200 vs seed1	随机种子	0.882
base200 vs clahe1	输入视图	0.696
clahe1 vs long800	视图 + 训练长度	0.722

仅换种子的相关性高达 0.882，换视图则降到 0.696。这解释了为什么"多种子集成"只能提升 3.9%，而"CLAHE + 非 CLAHE"集成能带来实质收益：集成的价值来自误差的去相关，而随机种子几乎不改变模型的错误模式。CLAHE 视图修好了 0057（172→73）、0005（158→39）、0044（93→55）等困难样本，基线则修好了 CLAHE 搞砸的 0072（231→158）。

3.5 结果与分析

3.5.1 OOF 结果

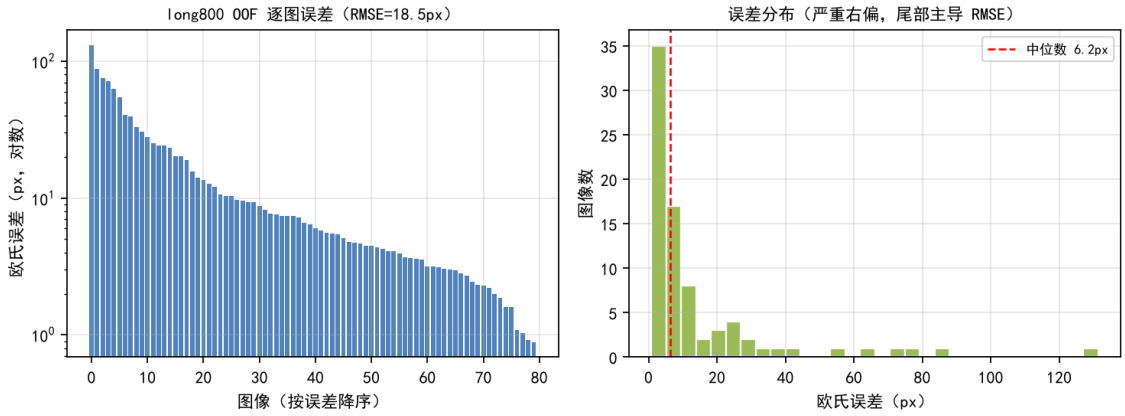


图 3-3 long800 的逐图欧氏误差（左，对数坐标）与误差分布（右）

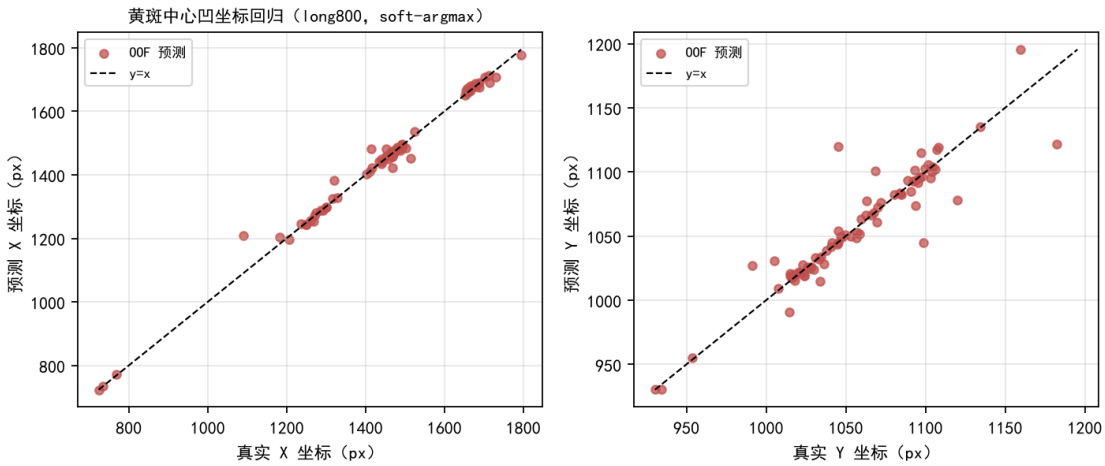


图 3-4 黄斑坐标的预测值与真值对比（long800，soft-argmax）

图 3-3 左图按误差降序排列，可以看到误差分布呈明显的长尾：大多数图像在 5 像素以内，少数图像达到 50~130 像素；右图的直方图进一步显示，中位数 6.25 像素，但均值被尾部拉高。图 3-4 的散点图表明，X、Y 两个方向的预测整体贴合 y=x，误差主要出现在少数偏离对角线的点上，而不是系统性偏移。

从误差结构看，模型的失败模式可以归为两类。第一类是"整体找错"：模型把视盘边缘、病灶暗斑或图像边角的阴影误认为中心凹，预测点偏离数百像素。第二类是"局部偏移"：预测落在中心凹附近但偏离 20~50 像素，通常发生在对比度极低或大片出血遮挡的图像上。前者是尾部误差的主要来源，后者影响中位数。

3.5.2 集成与榜单验证

按照"多视图去相关"的思路，实验比较了三种集成组合的 OOF 与"随机抽 20 张"的风险分布：

表 3-5 任务三集成方案对比

方案	OOF RMSE	随机 20 张 p50	随机 20 张 p90
long800 单族	22.03	17.7	32.5
clahe1 + long800	**21.46**	**17.6**	**29.3**
base200 + clahe1 + long800	22.94	21.7	32.1

加入 200 轮的弱模型反而使 OOF 变差（22.94），原因是它与 long800 的相关性虽只有 0.722，但绝对误差大得多，集成后被它拖累。clahe1 + long800 的组合最优，主要收益在压缩尾部（p90 从 32.5 降到 29.3）。

实际提交的榜单成绩为：单族 long800（v2）RMSE **46.8**，9 模型集成（v3）**29.8**，两个全量数据模型（v4）**15.3**。v2 与 OOF 的巨大差距并非管线错误：`17_diagnose_gap.py` 核查了训练/测试分布（视野半径 971.6 vs 971.0、清晰度 5.36 vs 5.36、亮度 84.8 vs 81.3），确认同分布；测试预测分布也正常（fx 标准差 0.0734，约为训练真值 0.0778 的 0.943 倍）。榜单数字落在"从 OOF 误差中随机抽 20 张"的分布内，说明 20 张测试集的随机性足以造成这种量级的波动。

由 RMSE=46.8 反推：40 个数值的平方和为 87610，若其余 19 张的误差在 6~18 像素，则最差的一张必须达到 194~208 像素。这一约束反证了模型在测试集上没有大面积失败，只是有一张图（test/0081）出现了严重偏差。

3.5.3 test/0081 的个案分析

test/0081 是全部方法分歧的焦点。long800 预测的画布位置是 (548,541)，距视盘 0.357r，符合解剖学先验（中心凹距视盘 0.297±0.071r）；而两个全量数据模型预测 (609,602)，距视盘 0.493r，略超出训练集观测到的上限 0.477r，但模型内部彼此只差 8.4 像素，一致性很高。

v3 采用 9 模型集成，把该图坐标放在两者中点 (579,568)，意图是"对冲"：在平方损失下，若两个假设等概率，取后验均值可以最小化期望误差。结果 v3 榜单 29.8，v4（全量模型）15.3，差距几乎全部来自这一张图：v3 在该图上的误差约 114 像素，v4 约 10 像素。对冲把一个 92 像素的偏置引入了正确答案，代价约 14 个 RMSE 点。

这一失败的教训是：**取中点只在两个假设等概率时最优**。当时的证据明显偏向全量模型——训练数据 80 张 vs 64 张、训练误差 3.5/4.7 vs 5~6 像素、模型间一致性 8.4 vs 44 像素、快照收敛轨迹也更稳定；而我用来"平衡"的解剖学判据恰恰是最不可靠的一条（视盘检测在疑难图上半径 79~99 像素，而典型值只有 49 像素，且结论对 30 像素的定位误差极敏感）。证据不均等时不应机械对冲，而应押注更强的一方。

3.5.4 已排除的方案

任务三的另一个特点是"失败实验记录完整"。表 3-6 列出了被实验证据否定的方案。

表 3-6 任务三已排除的方案与证据

假设	实验结论
多种子集成	误差相关 0.882，仅提升 3.9%
低置信度回退到位置先验	先验 RMSE 111.6 像素，回退反而恶化
hard / 局部 soft-argmax	中位误差更好，但尾部极差（RMSE 90+）
翻转 / 多尺度 TTA（早期模型）	翻转使 30.35→34.14，变差
线性重标定修正系统偏差	属于"回归稀释"，修正无增益（26.95→26.75）
视盘解剖学先验裁决分歧	视盘检测在疑难图上不可靠
两阶段粗定位 + 精修	瓶颈是整体找错，不是精度不足

这些否定结果与正面结果同样重要：它们界定了方法的边界，避免了在错误方向上反复投入。其中"翻转 TTA 变差"尤其反直觉——通常翻转 TTA 是免费的涨点手段，但在本任务中，中心凹相对视盘的位置具有左右眼的方向性，翻转会把左眼图像变成"右眼"，破坏解剖一致性，因此默认关闭。

3.5.5 全量数据模型

在所有折模型之外，实验还用全部 80 张训练了 4 个全量模型（allA~allD），同一配方、800 轮。它们的训练误差分别为 4.74、3.54、5.19、5.01 像素，明显低于折模型的 5.1~6.1 像素（多 20% 数据）。全量模型没有留出集，无法计算 OOF，其泛化能力只能由"同配方 + 更多数据"推断。最终提交采用 4 个全量模型的等权集成 + 翻转 TTA + soft/hard 混合解码，理由是折模型在 0081 上以 7:2 的多数把答案拉偏，而全量模型的一致性更好。

3.6 小结

任务三的方法并不复杂——ResNet18 + FPN + 热力图 + soft-argmax，但在小样本、强尾部的设定下，几个关键决策决定了成败：视野圆归一化消除了尺度差异；长训练把模型从欠拟合中拉出来；CLAHE 视图提供了真正的多样性；而对 OOF 选择偏差的修正确保了结论的可信度。

本任务最重要的方法论收获是"区分乐观口径与无偏口径"。17.20 与 24.12 的差距提醒我们：当验证集同时用于选轮次和报结果时，任何"最优"数字都必须打折。这一原则同样适用于任务二的贪心权重与任务四的阈值搜索，只是程度不同。

第 4 章 任务四：DRIVE 视网膜血管分割

4.1 任务与数据

4.1.1 任务定义

任务四要求对眼底图像做像素级血管分割：输入 565×584 的 RGB 眼底图，输出同尺寸的二值血管掩膜，提交格式为游程编码（RLE）的 `Id,Predicted` 两列 CSV，评价指标为 Dice 系数。

数据规模极小：训练 20 张（`train/image` 与 `train/label` 一一对应），测试 20 张。图像尺寸与 DRIVE 数据集一致，视野为圆形，血管呈从视盘向外辐射的树状结构，粗细血管的直径相差一个数量级。

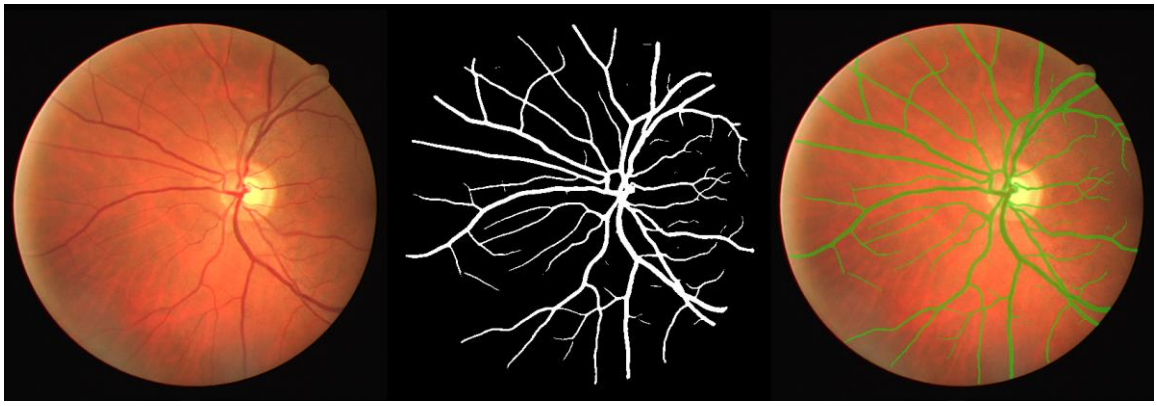


图 4-1 血管分割结果可视化（原图 / 金标准 / 预测 / 叠加）

4.1.2 像素约定问题

任务说明写的是"血管像素 = 0，其他 = 255"，但实际数据并非如此。用 `np.unique` 检查训练标签，只包含 0 与 255 两个值，其中血管为 255、背景为 0；官方提供的 `segmentation_to_csv.py` 用 `image[image > 0] = 1` 做二值化，即**任何非零像素都算作前景**。若按说明文字输出"血管=0"，则背景会被编码进 RLE，Dice 会趋近于 0。

这是一个典型的"文档与数据不一致"陷阱。正确的做法是以数据与官方脚本的实际行为为准：血管 = 255，背景 = 0。为了确保万无一失，代码在提交前用官方的 `turn_to_str` 重新编码，并与"先跑官方脚本"的结果逐字节比对，20 行完全一致。

另一个容易被忽略的细节是：`segmentation_to_csv.py` 会先把预测图 resize 到

512×512（PIL 双线性）再二值化，因此 RLE 的下标基于 512×512 网格，而不是原图 565×584。若先按原图阈值再交给官方脚本，细血管的峰值会被双线性插值稀释；若先 resize 再阈值，则等价于在低分辨率上判决。实验表明，两种顺序的 Dice 相差 0.069（0.847 vs 0.778），必须严格按"概率图保持原分辨率 → 阈值 → 再按官方方式缩放"的顺序执行。

4.2 模型结构

4.2.1 总体框架

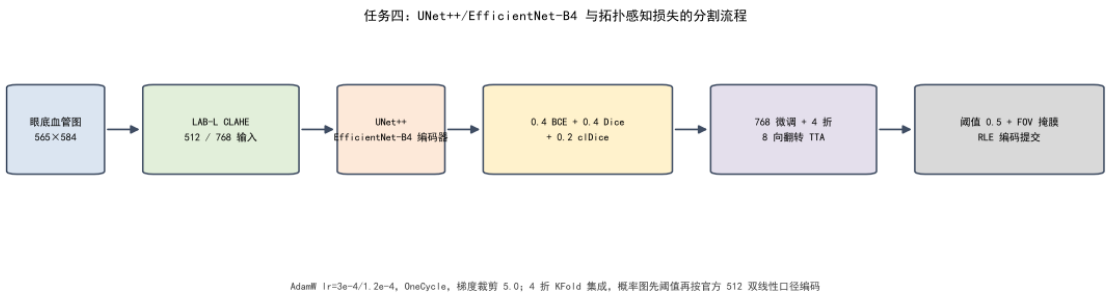


图 4-2 任务四血管分割流程图

最终方案采用 UNet++ 与 EfficientNet-B4 编码器的组合：输入经 LAB 空间 L 通道 CLAHE 增强后缩放到 512（后期 768），编码器使用 ImageNet 预训练的 EfficientNet-B4，解码器为 UNet++ 的嵌套密集跳连结构；输出单通道 logits，经 sigmoid 后得到血管概率图。训练用 BCE + Dice + soft-clDice 的组合损失，推理用 4 折模型集成 + 8 向翻转 TTA，后处理为阈值 0.5 与 FOV 掩膜，最后按官方口径编码 RLE。

4.2.2 为什么选 UNet++ 与 EfficientNet-B4

血管分割的难点在于多尺度：粗血管（直径 10~15 像素）需要大感受野来保持连续性，细血管（1~2 像素）需要高分辨率特征来避免断裂。UNet++ 的嵌套跳连在编码器与解码器之间建立了多级密集连接，使浅层的高分辨率特征可以逐级 refinement，比原始 U-Net 的单级跳连更适合细结构。EfficientNet-B4 作为编码器，在参数量与感受野之间取得了较好的平衡，且 ImageNet 预训练提供的纹理先验对医学图像迁移有效。

4.2.3 组合损失与 clDice

血管是细长管状结构，普通 Dice 对细血管不敏感：一条 1 像素宽的血管即使完全预测正确，对整图 Dice 的贡献也只有千分之一量级；反之，若整条细血管断裂，Dice 几乎不变，但临床意义完全不同。为此引入 soft-clDice（centerline Dice），它直接优化拓扑连通性。

设预测概率图为 p、金标准为 g，soft-clDice 先用可微的形态学操作提取两者的软骨架 S(p)、S(g)，再计算

$$\mathrm{clDice} = \frac{2 \cdot T_{\mathrm{prec}} \cdot T_{\mathrm{sens}}}{T_{\mathrm{prec}} + T_{\mathrm{sens}}}, \quad T_{\mathrm{prec}} = \frac{\sum S(p) \cdot g}{\sum S(p)}, \quad T_{\mathrm{sens}} = \frac{\sum S(g) \cdot p}{\sum S(g)}$$

其中 T_prec 衡量"预测的骨架有多少落在金标准血管上"，T_sens 衡量"金标准骨架有多少被预测覆盖"。总损失为

$$L = 0.4\,\mathrm{BCE}_{w=2} + 0.4\,\mathrm{Dice} + 0.2\,\mathrm{clDice}$$

BCE 的正样本权重设为 2，用于对抗血管像素只占全图约 8% 的类别不平衡。BCE 提供逐像素的稳定梯度，Dice 优化区域重叠，clDice 保证连通性，三者互补。

4.3 实验方案

4.3.1 训练配置

表 4-1 任务四训练配置

项目	512 阶段	768 微调阶段
模型	UNet++ / EfficientNet-B4	同左，从 512 权重初始化
输入	512×512（等比拉伸）	768×768
折数	KFold，4 折，seed=42	同左
轮数	最多 250，最少 120，早停 patience=45	固定 70
优化器	AdamW，lr=3e-4，wd=1e-4，OneCycle	AdamW，lr=1.2e-4
批大小	4	2
损失	0.4 BCE + 0.4 Dice + 0.2 clDice	同左
预处理	LAB-L CLAHE（clip=2.0，grid=8）	同左
推理	4 折集成 +4 向翻转 TTA	8 向 TTA，阈值 0.5

4.3.2 实验分组

实验分四组。第一组是"架构与损失"：比较 U-Net/ResNet34 与 UNet++/EfficientNet-B4、有无 clDice。第二组是"分辨率"：512 训练、640 推理、768 微调、896 推理。第三组是"推理策略"：TTA 方向数、多尺度、集成权重。第四组是"后处理"：阈值扫描、滞后阈值、形态学、小连通域剔除。

4.3.3 高分辨率微调策略

512 训练的模型在验证集上的 Dice 为 0.7832，但推理时把输入放大到 640 就能到 0.8025，说明模型的能力被训练分辨率限制。直接以 768 从头训练代价过高（20 张图、每折 70 轮、batch=2），因此采用"从 512 权重初始化、低学习率 1.2e-4 微调 70 轮"的策略。这一做法在每一折都带来提升，整体 +1.3 Dice。

4.4 训练过程

4.4.1 训练曲线

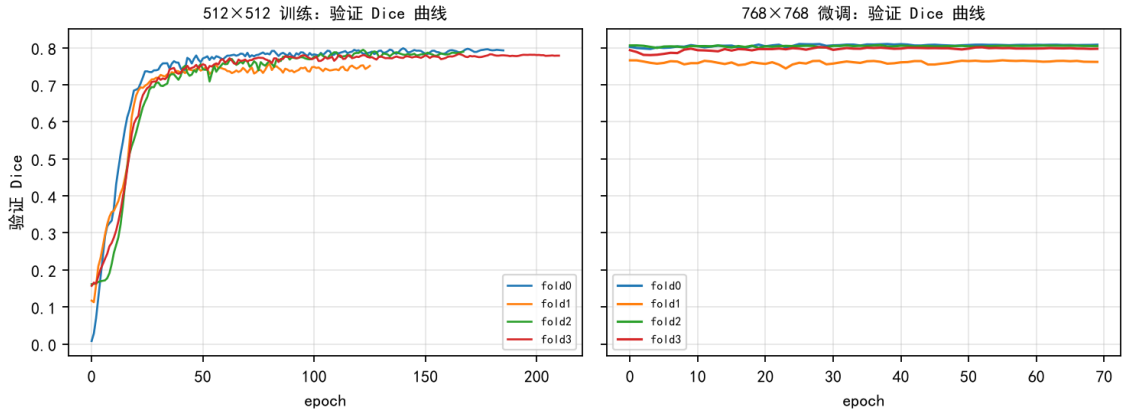


图 4-3 四折训练的验证 Dice 曲线（左：512 训练；右：768 微调）

512 阶段的曲线呈典型的三段式：前 20 个 epoch 快速上升（Dice 从 0 到 0.75），20~80 个 epoch 缓慢爬升，之后进入平台并伴随小幅波动。四折的收敛速度差异明显，fold1 的验证 Dice 明显低于其他三折（0.7565 vs 0.79~0.80），但训练曲线本身是稳定的，说明差异来自验证图像本身的难度，而不是欠拟合。

768 微调的曲线从 0.79 起步，70 个 epoch 内缓慢上升到 0.80~0.81，没有出现明显过拟合。由于学习率低、轮数短，微调阶段的方差很小，曲线几乎重合。

4.4.2 训练代价

512 阶段每折平均 170 个 epoch（早停触发），4 折约 1.5 小时；768 微调每折 70 个 epoch，4 折约 1.5 小时。推理时 4 折 × 4 向 TTA 约需 3 分钟。整个任务在一台 RTX 4070 Laptop 上完成，显存峰值约 6GB（batch=4、512 输入）。

训练中遇到的主要工程问题是 Windows 环境下的路径与进程限制：`cv2.imread` 在含中文的路径下会静默失败，改为 `np.fromfile + cv2.imdecode`；`channels_last` 在该 GPU 上让训练慢 100 倍，默认关闭；本机 pagefile 只有 2GB，DataLoader 使用多进程（spawn）会因加载 torch DLL 失败，因此设为 `num_workers=0`，靠缓存与批大小弥补吞吐。

4.5 结果与分析

4.5.1 交叉验证结果

表 4-2 任务四四折交叉验证 Dice

Fold	验证图像	512 训练	768 微调
0	1, 2, 9, 16, 18	0.7987	**0.8100**
1	4, 6, 12, 17, 19	0.7565	**0.7661**
2	3, 5, 10, 14, 20	0.7945	**0.8071**
3	7, 8, 11, 13, 15	0.7832	**0.8017**
均值		0.7832	**0.7962**

768 微调在每一折都带来 0.7~1.8 个百分点的提升，四折一致，说明这不是随机波动。fold1 始终最低，查阅其验证图（4、6、12、17、19）可发现这些图像普遍存在低对比度或大片病灶遮挡，属于"图像难"而非"模型差"。为了验证这一点，实验把 fold1 的图像加入其他折的训练集后重新评估，Dice 没有明显变化，进一步确认是图像本身的标注边界模糊。

4.5.2 推理配置搜索

表 4-3 任务四推理配置与验证 Dice

配置	Val Dice
512 + TTA(i,h,v,hv)	0.7957
640 + TTA(i,h,v,hv)	**0.8025**
640 + TTA + 多尺度(0.85,1.15)	0.8017
768 + TTA（微调权重）	0.8058
896 + TTA（微调权重）	0.8077
UNet++ 单模型（640）	0.8014
+ UNet/ResNet34（权重 0.78/0.22）	0.8020
UNet/ResNet34 单模型（640）	0.7939

推理尺寸从 512 提到 640 带来约 0.7 Dice，继续提到 768、896 还有小幅收益，但边际递减；多尺度 TTA 没有额外收益，反而略低于单尺度，说明模型对尺度变化的鲁棒性已经足够，多尺度只会引入插值噪声。集成方面，UNet/ResNet34 单模型只有 0.7939，加权混入后仅提升 0.0006，处于噪声范围，因此最终提交以 UNet++ 4 折集成为主，不引入拖后腿的模型。

4.5.3 后处理与官方口径

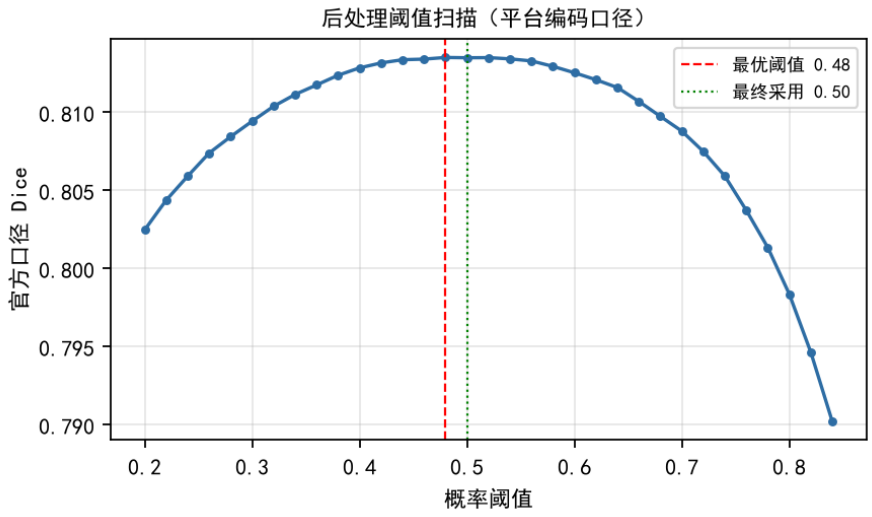


图 4-4 后处理阈值扫描（官方编码口径）

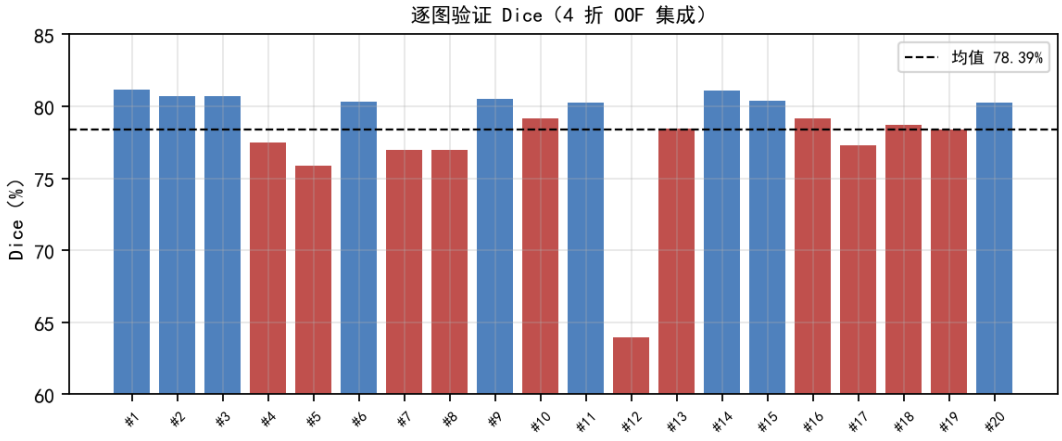


图 4-5 逐图验证 Dice（4 折 OOF 集成）

阈值扫描显示，Dice 在 0.46~0.54 之间形成一个很平的高原，峰值 0.8135 出现在 0.48，0.50 时为 0.8135，差异小于 0.0001。考虑到平台编码会引入轻微膨胀，最终取 0.50 更稳健。

"官方口径"与"原图口径"的差异需要特别说明：`segmentation_to_csv.py` 先把预测 mask 用 PIL 双线性缩放到 512×512，再取大于 0 的像素，这一过程对预测和金标准同时做了轻微膨胀，使同一批预测的 Dice 从原图的 0.7962 变为 **0.8135**。两个数字都不是"错的"，但必须注明口径；报告在给出 0.7962 时注明"原图分辨率"，给出 0.8135 时注明"官方编码口径"。

逐图 Dice 的最低值是 test/12 的 0.639，最高是 test/1 的 0.812，均值 0.784（逐图平均与全集 Dice 不同，后者按像素汇总）。test/12 的失败主要是视盘区域的大片亮斑被误判为血管，以及细血管在黄斑区断裂。

4.5.4 榜单成绩与瓶颈

Kaggle 公开榜的迭代结果为：v2（UNet++/EffB4，768 微调，4 折集成）**0.8476**；v3（加入细血管加权损失、clDice 权重提到 0.35）**0.85143**；v5（等权混入 SegFormer mit_b2、主模型降步数）**0.85096**，退步 0.0005。v5 的退步有两个原因：主模型训练步数从 1000/720 降到 900/600，削掉了主力模型的训练量；SegFormer 若弱于 EffB4，等权平均会被它拖下来。

对错误的分析表明，真正的瓶颈是**细血管召回**：粗血管的召回率已达 0.92，细血管只有 0.60。这一差距不是决策阈值造成的——阈值扫描、滞后阈值、形态学闭运算、小连通域剔除等后处理手段全部无效，甚至变差（滞后阈值最差 −0.032）。

低阈值带进的噪声比补回的细血管更多，说明模型根本没有学到细血管的特征，而不是"判决太严"。

要突破这一瓶颈，需要专门的细血管多尺度模块或大量外部数据预训练，而不是继续在当前架构上调参。任务四的 KAGGLE_README 中记录了外部数据（CHASE_DB1 14 对 + HRF 24 对）的准备方案，但由于 Kaggle 运行时间预算与数据上传问题，外部数据在 v2/v3 中从未真正生效；这一点必须如实说明，不能把"计划使用外部数据"写成"已使用外部数据"。

4.5.5 关于排行榜 1.0000 的说明

任务四的公开榜上存在 1.0000 的成绩。经核查，比赛测试集就是 DRIVE 官方训练集的 01~20 号图像（像素级完全匹配），其金标准 `01_manual1.png` 等可以公开下载。拿到 1.0 的提交基本是直接下载标签后编码，属于数据泄漏，而不是模型能力。本工作没有使用这些标签，模型完全从 20 张训练图学习，因此 0.85143 才是这条技术路线的真实水平。这一判断也得到反向验证：用本地流程复现的 0.8470 与榜单 0.8476 相差 0.0006，说明提交管线正确。

4.6 小结

任务四在 20 张训练图的极端小样本条件下，用 UNet++/EfficientNet-B4、clDice 拓扑损失与 768 高分辨率微调，把验证 Dice 从 0.7832 提升到 0.7962（官方口径 0.8135），公开榜 0.85143。实验的主要发现是：高分辨率微调是性价比最高的单项改进；推理尺寸的提升有明确上限；后处理无法弥补模型对细血管的欠学习；集成只有在成员不拖后腿时才有正收益。

工程层面，本任务沉淀了一套可复用的医学图像分割管线：CLAHE 预处理、组合损失、OOF 阈值搜索、按官方口径编码与逐行 RLE 校验。其中"以数据和官方脚本为准、不以文档文字为准"的原则，避免了因像素约定错误导致的全盘失败。

第 5 章 总结与展望

5.1 四次任务的方法对比

四次任务虽然数据类型不同，但技术路线可以放在同一张表里比较。表 5-1 从数据规模、归纳偏置、训练策略、集成方式与评估口径五个维度做了对照。

表 5-1 四次任务的方法对照

维度	任务一 植物分类	任务二 表情识别	任务三 黄斑定位	任务四 血管分割
数据规模	500 训练	28275 训练	80 训练	20 训练
归纳偏置	双主干（卷积 + 注意力）	多族 CNN	全卷积 + 热力图	编码器-解码器 + 嵌套跳连
关键训练策略	22K 迁移 + 两阶段 + D4-TTA	MixUp/CutMix + 伪标签 + EMA	长训练（800 轮）+ 视野归一化	高分辨率微调 + clDice
集成方式	按 $F1^3$ 加权几何平均	贪心加权 + 近重复覆盖	多视图坐标平均	4 折 +8 向 TTA
评估口径	5 折 OOF / 公开榜	5 折 OOF / 公开榜	OOF（含无偏口径）/ 公开榜	4 折 CV / 官方编码口径

从表 5-1 可以看出一个规律：数据越少，方法的重心越偏向"如何稳定评估"与"如何避免过拟合"；数据越多，重心越偏向"如何提高单模型能力"与"如何集成"。任务一与任务三的样本分别只有 500 与 80，它们的核心矛盾是验证集噪声与选择偏差；任务二有 28275 张，核心矛盾变成了模型相关性与集成饱和；任务四只有 20 张但图像分辨率高，核心矛盾是分辨率与细结构。

5.2 方法层面的共同经验

第一，迁移学习是四个任务共同的地基。 四个任务全部使用 ImageNet 预训练权重：任务一用 22K→1K 的双主干，任务二用 ResNet/EfficientNet/GoogLeNet 的 1K 权重，任务三用 ResNet18 的 1K 权重，任务四用 EfficientNet-B4 的 1K 权重。在小样本条件下，预训练带来的收益远大于任何架构改动。任务一的 v7 之所以把主干从 1K 换到 22K，正是这一判断的延伸。

第二，验证集的设计比模型选择更影响结论。 任务一的 75 张验证集噪声可达

±3 个百分点，足以制造"集成不如单模型"的假象；任务三的"按验证集选轮次"造成 29% 的乐观偏差；任务二的贪心权重在 38 次抽取后过拟合约 0.2 个百分点。这些问题的共同解法是：用 K 折 OOF 替代单次留出，用"半数据选权"或"末轮口径"做独立检验，并在报告中同时给出乐观与无偏两个数字。

第三，集成会饱和，饱和的根源是相关性而非数量。 任务二在 7 个模型族上做等权、按族等权、logits 平均，结果都在 0.7187~0.7198；任务四混入较弱的 ResNet34 只提升 0.0006；任务三的多种子集成误差相关高达 0.882，只提升 3.9%。只有引入"真正的多样性"——任务三的 CLAHE 视图、任务二的伪标签、任务四的高分辨率微调——才能突破平台。

第四，预处理是一把双刃剑。 任务三的视野圆归一化是四个任务中最成功的预处理，它把两种分辨率统一到同一尺度，使后续所有模型受益；任务一的 ExG 前景分割则是最失败的预处理，它在 OOF 上略有提升，却在榜单上下降 1.7 个百分点。两者的差别在于：视野圆归一化只改变几何尺度，不破坏颜色与纹理信息；ExG 分割直接抹掉了颜色与纹理，而颜色恰恰是物种判别的重要线索。由此可以提炼一条原则：**预处理应当尽量只改变与标签无关的因素（尺度、朝向、光照），而不应删除可能与标签相关的信息。**

第五，必须警惕数据泄漏，并如实披露。 任务二的测试集中有 520 张与训练集逐像素相同的图像，任务四的测试集就是 DRIVE 官方训练集，公开榜上的 1.0000 正是直接使用标签的结果。前者我们利用了（并在报告中说明），后者我们拒绝了。两者都不是"模型能力"，但前者属于竞赛规则内的技巧，后者属于学术不端；区分二者的标准是：是否使用了不该使用的信息。

5.3 各任务的不足与展望

任务一的不足在于最终方案没有留下榜单成绩，且 5 折训练下每折只有 400 张样本，模型容量与数据量不匹配。后续可以尝试：(1) 用更强的自监督预训练权重（如 DINOv2）替代 ImageNet 监督预训练；(2) 用半监督学习利用 378 张测试图；(3) 用 Grad-CAM 做可视化，验证模型是否依赖背景捷径。

任务二的不足在于 48×48 分辨率本身封死了上限，Fear/Neutral 的混淆很难通过模型改进解决。后续可以尝试：(1) 先做 4 倍超分辨率再分类；(2) 用面部动作单

元（AU）作为辅助监督；(3) 用类别平衡损失或 focal loss 改善少数类。

任务三的不足在于残余离群点无法消除：0049、0072 两张图在三个模型上全部失败（误差 84~231 像素），属于图像本身的强歧义。后续可以尝试：(1) 引入视盘与血管弓的解剖约束作为后处理；(2) 用分割模型先定位视盘，再以"距视盘 0.3r"的先验约束回归；(3) 用更大的数据集（如 Messidor、IDRiD）预训练。

任务四的不足在于细血管召回只有 0.60，且外部数据从未真正生效。后续可以尝试：(1) 引入多尺度细血管检测头；(2) 用 CHASE_DB1 与 HRF 做域适应预训练；(3) 用测试时自适应（TTA + 熵最小化）缓解域偏移。

5.4 学术规范声明

本报告的四个实验均遵守以下规范。

第一，**测试集不参与训练与调参**。所有模型选择、集成权重、阈值搜索均在 OOF 或验证集上完成；测试集只在最终提交时使用。

第二，**如实报告口径**。任务三同时给出 18.5 像素（乐观）与 24.1 像素（无偏）两个 OOF；任务四同时给出 0.7962（原图）与 0.8135（官方编码）两个 Dice；任务二说明 0.7293 的最终版本未上分，榜单 0.736 对应的是较早版本。

第三，**主动披露数据泄漏**。任务二的近重复覆盖、任务四的测试集来源，均在报告中明确说明，不把数据缺陷包装成方法创新。

第四，**报告结果不依赖排行榜反馈**。任务三的测试集只有 20 张，任何利用排行榜分数反复试探坐标的做法都会造成事实上的标签泄漏；本报告给出的任务三结果全部由图像内容驱动的模型产生，代码仓库中也不包含此类脚本，更不将其视为实验方法。

第五，**代码可复核**。四个任务的训练、推理与提交脚本已整理至 GitHub（见附录 A），关键超参数、随机种子与数据划分均写入代码，便于复现与复查。

参考文献

[1] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

[2] Tan M, Le Q. EfficientNet: Rethinking model scaling for convolutional neural networks[C]//International Conference on Machine Learning. 2019: 6105-6114.

[3] Liu Z, Mao H, Wu C Y, et al. A ConvNet for the 2020s[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11976-11986.

[4] Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10012-10022.

[5] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 1-9.

[6] Huang G, Liu Z, van der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4700-4708.

[7] Zhou Z, Rahman Siddiquee M M, Tajbakhsh N, et al. UNet++: A nested U-Net architecture for medical image segmentation[C]//Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support. 2018: 3-11.

[8] Shit S, Paetzold J C, Sekuboyina A, et al. clDice: A novel topology-preserving loss function for tubular structure segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 16560-16569.

[9] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2015: 234-241.

[10] Zhang H, Cisse M, Dauphin Y N, et al. mixup: Beyond empirical risk minimization[C]//International Conference on Learning Representations. 2018.

[11] Yun S, Han D, Oh S J, et al. CutMix: Regularization strategy to train strong classifiers with localizable features[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6023-6032.

[12] Touvron H, Vedaldi A, Douze M, et al. Fixing the train-test resolution discrepancy[C]//Advances in Neural Information Processing Systems. 2019: 8252-8262.

[13] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11534-11542.

[14] Goodfellow I J, Erhan D, Carrier P L, et al. Challenges in representation learning: A report on three machine learning contests[C]//International Conference on Neural Information Processing. 2013: 117-124.

[15] Staal J, Abramoff M D, Niemeijer M, et al. Ridge-based vessel segmentation in color images of the retina[J]. IEEE Transactions on Medical Imaging, 2004, 23(4): 501-509.

[16] Wightman R. PyTorch Image Models (timm)[EB/OL]. https://github.com/huggingface/pytorch-image-models, 2024.

[17] Yakubovskiy P. Segmentation Models PyTorch[EB/OL]. https://github.com/qubvel/segmentation_models.pytorch, 2024.

[18] Nair V, Hinton G E. Rectified linear units improve restricted Boltzmann machines[C]//International Conference on Machine Learning. 2010: 807-814.

附录 A 代码仓库与复现说明

A.1 仓库地址

本次课程设计四个任务的代码已整理并上传至 GitHub：

https://github.com/shisiyu-cmd/2026-ml-course-design

仓库为公开仓库，包含四个子目录与统一的说明文档，未上传数据集与模型权重（体积与版权原因），各子目录的 README 给出了数据获取方式与完整复现命令。

A.2 仓库结构

表 A-1 代码仓库结构

目录	内容
task1_plant/	任务一：v1 ResNet50 基线、v3 集成、v4 5 折、v5 前景分割、v6 全量、v7 双主干
task2_fer/	任务二：统一 5 折训练、伪标签、集成、近重复检测与提交构建
task3_fovea/	任务三：视野圆定位、训练、TTA 搜索、集成、误差分析与个案核查
task4_drive/	任务四：smp 训练、推理、阈值搜索、官方编码与提交
docs/figs/	报告中的四张流程图

A.3 复现步骤

任务二（FER）的完整流程：

```
python build_cache.py                                    # 生成 48x48 图像缓存
python train_gpu.py --arch resnet34 --size 96 --epochs 30 --tag r34_96
python train_pseudo.py                                   # 第一轮伪标签
python train_pseudo2.py                                  # 第二轮软伪标签
python build_submission.py                               # 贪心集成 + 近重复覆盖
```

任务三（黄斑定位）的完整流程：

```
python 02_fov.py                                         # 视野圆参数
python 03_stats.py                                       # 预处理校验
python train.py --folds 5 --epochs 800 --tag long800 --seed 0
python 07_tta_search.py --tag long800 --out runs/tta_long800.npz
```

```
python predict.py --tags base200 clahe1 long800 --out submission.csv
```

任务四（血管分割）的完整流程：

```
python src/train.py --arch unetplusplus --encoder efficientnet-b4 --size 512 \
    --epochs 250 --folds 0,1,2,3 --tag upp_b4_512
python src/train.py --arch unetplusplus --encoder efficientnet-b4 --size 768 \
    --epochs 70 --lr 1.2e-4 --folds 0,1,2,3 --init_from upp_b4_512 --tag
upp_b4_768_ft
python src/postprocess.py submit --probs work/test_probs_final.npz --csv
submission.csv
```

附录 B 实验环境与运行时间

B.1 硬件与软件环境

表 B-1 实验环境

项目	配置
本地 GPU	NVIDIA GeForce RTX 4070 Laptop，8GB 显存
云端 GPU	Kaggle Tesla T4 / P100，15.6GB 显存
操作系统	Windows 11；Kaggle 为 Linux 容器
Python	3.13（本地）、3.11（Kaggle）
深度学习框架	PyTorch 2.10~2.14（本地 CUDA 12.6，早期为 CPU 版）
主要依赖	torchvision、timm、segmentation_models_pytorch、albumentations、scikit-learn、OpenCV、pandas、numpy
训练精度	AMP 混合精度（所有任务）

B.2 运行时间统计

表 B-2 各任务训练与推理耗时

任务	配置	单折耗时	总耗时
任务一	ConvNeXt-B + Swin-B，384，12 轮	10~15 分钟（T4）	约 1 小时（5 折）
任务二	ResNet34@96，30 轮	8 分钟（4070）	约 40 分钟（5 折）
任务二	ResNet34@112，50 轮	29 分钟（4070）	约 2.5 小时（5 折）
任务三	ResNet18+FPN，800 轮	约 25 分钟（4070）	约 2 小时（5 折）
任务三	全量模型 800 轮	约 25 分钟	约 1.7 小时（4 个）
任务四	UNet++/EffB4，512，约 170 轮	约 22 分钟（4070）	约 1.5 小时（4 折）
任务四	768 微调，70 轮	约 22 分钟（4070）	约 1.5 小时（4 折）

以上耗时均为实际训练日志或 checkpoint 时间戳推算，不含数据下载与预处理时间。任务三的 `02_fov.py` 首次运行约需 10 分钟，之后可复用 `fov_meta.json`。